TECNOLÓGICO DE MONTERREY · MNA · ENTREGA FINAL (SEMANAS 1–8)

Sistema Prescriptivo MLOps de Pronóstico de Demanda, Simulación What-If y Desagregación por SKU

Operación automatizada de punta a punta en Azure Databricks Serverless y Tablero AI/BI para ~17,000 Tiendas SIX (Bnext)

Equipo 43 · Autores

- Daniela Juárez Ortiz (A01797369)
- Kevin Alexis Valdez Pérez (A01750478)
- Yael Ariel Márquez Mas (A01745310)

Vinculación Institucional

- Socio Formador: Tiendas SIX & Bnext
- Patrocinador Institucional: Dr. Juan Arturo Nolazco Flores
- Asesora Académica: Dra. Eduviges Ludivina Facundo

Entorno de Producción

- Plataforma: Azure Databricks Serverless (Jobs & Lakeview AI/BI)
- Catálogo Unity Catalog: modeladoprescriptivoventas.maestria
- Estado de Cierre (Nov 2026): 5 Jobs listos · J4 validado en verde

Confidencialidad (MODO_PUBLICO = True): métricas expresadas en tasas relativas auditadas; los importes privados permanecen dentro de Unity Catalog.

El sistema resuelve el dilema entre quiebres de anaquel y sobrestock en ~17,000 tiendas

+20.0%

Mejora vs. Ingenuo (Prueba)

WMAPE 0.4535 vs. 0.5668 en septiembre no visto

-3.82%

Sesgo Monetario Controlado

Dentro de ±5% (corrige -24.4% del enfoque Log1p)

82.0%

Cobertura Conformal P10–P90

14/14 horizontes dentro de banda meta 75%–85%

~77 min

Inferencia Completa J4

Pronóstico listo en 19m (vs. 4–6 h de reentrenar)

1. El Problema Comercial

• Pronosticar diariamente 14 días hacia adelante para miles de combinaciones tienda × categoría con >52% de días en cero (y >83% en SKU directo).

• El modelo previo basado en log(1+y) sufría sesgo matemático de Jensen (-24.4% a -35.9%), induciendo quiebres de inventario en fines de semana y quincenas.

• Además, la operación requería reentrenar horas enteras para obtener un nuevo pronóstico.

2. La Solución Científica

• Ensamble heterogéneo convexo E3 · Blending entrenado en escala natural sobre 62 variables 100% libres de fuga temporal (≤ T).

• Bandas calibradas con Q_Conformal que separan la meta financiera (P50) del techo protector de abasto (P90).

• Desagregación jerárquica Top-Down a Top 15 SKUs + fila OTROS con reconciliación 100% aditiva y simulador What-If contrafactual.

3. Industrialización MLOps

• 25 notebooks modulares gobernados en Unity Catalog (Bronce → Plata → Oro → MLOps).

• 5 Jobs Serverless en Databricks Workflows encadenados con tareas Run Job (J1 → J2 → J4) y gobierno @challenger → @champion.

• Tablero nativo AI/BI de 7 vistas publicado sobre SQL Warehouse Serverless sin extraer datos privados de Bnext.

Fuente: Evaluación formal Avance 5 (corte ciego septiembre) y corrida productiva J4 Inferencia (corte 31-oct-2026) en Azure Databricks.

Seis fases incrementales transformaron datos crudos POS en una plataforma MLOps productiva

Fase / Semana	Avance	Trabajo Técnico Ejecutado	Resultado / Hito Verificado
Fase 0–1 (Sem 1–3)	Avances 0 y 1	Planteamiento CRISP-ML(Q), ingesta Bronce (02) y EDA integral de series, tiendas y externas (04–07)	Detección de >52% ceros en categoría (>83% SKU), duplicados inter-mes y huecos postales
Fase 2 (Sem 4)	Avance 2	31 reglas en Plata (08), panel diario regular con ceros explícitos (09), rescate INEGI y Oro (20)	62 variables predictoras ≤ T · 0 filas con fuga temporal en 257,364 registros auditados
Fase 3 (Sem 5)	Avance 3	Backtesting walk-forward de 4 cortes a 14 días (10) y escalera baseline Naive vs. Log1p vs. Tweedie	Demostración del sesgo de Jensen (-24.4%); Tweedie baja WMAPE inicial de 0.5815 a 0.4991
Fase 4 (Sem 6)	Avance 4	Torneo de 10 modelos (21) en 30.47M filas, ajuste fino Optuna y explicabilidad Gain / Splits / SHAP	LightGBM Tweedie logra WMAPE 0.4503 (muestra) / 0.4562 (total) · Versión 1 en Unity Catalog
Fase 5 (Sem 7)	**Avance 5**	**14 formulaciones (individuales + ensambles) en Oro v13 (mar–sep), prueba ciega sep y Q_Conformal**	**Campeón E3 · Blending: WMAPE 0.4447 dev / 0.4535 prueba (+20.0%) · Cobertura real 82.0%**
Fase 6 (Sem 8)	**Avance 6**	**Inferencia separada (22), calendario Excel (13), What-If (30), SKU (31), monitoreo (23), 5 Jobs y AI/BI**	**Carga oct (2026-10-31), J4 Inferencia 100% en verde (horizonte 1–14 nov) y 7 vistas activas**

Metodología CRISP-ML(Q) · Cada fase resolvió hallazgos empíricos de la etapa previa dejando evidencia auditable en tablas Delta y MLflow.

La arquitectura Medallón garantiza cero fuga temporal en las 62 variables y en el plan promocional

1. Capa Bronce (02)

• Ingesta mensual parametrizada de archivos Parquet crudos desde Volúmenes.

• Conserva trazabilidad exacta de archivo origen, lote y marcas de carga en mlops_bronce_cargas.

• Homologa tipos sin alterar la evidencia original.

2. Capa Plata (08, 09, 11)

• Aplica 31 reglas de calidad: depura devoluciones, atípicos y duplicados entre cierres mensuales.

• Construye el panel diario continuo imputando ceros reales en tiendas abiertas.

• Compuerta 11 valida integridad antes de avanzar.

3. Plan Promocional (13)

• Traduce el Excel editable de negocio a tablas Silver diarias.

• Regla anti-fuga estricta con fecha_publicacion: cada corte T sólo ve campañas ya publicadas ≤ T.

• Soporta detalle por categoría o captura rápida TODAS.

4. Capa Oro (20)

• Grano (tienda, categoría, origen T, horizonte h=1..14).

• 62 variables: estado congelado en T (21), contexto tienda/zona (8), rezagos mismo día T+h-7k ≤ T (13), calendario ex-ante (12) y estáticas (8).

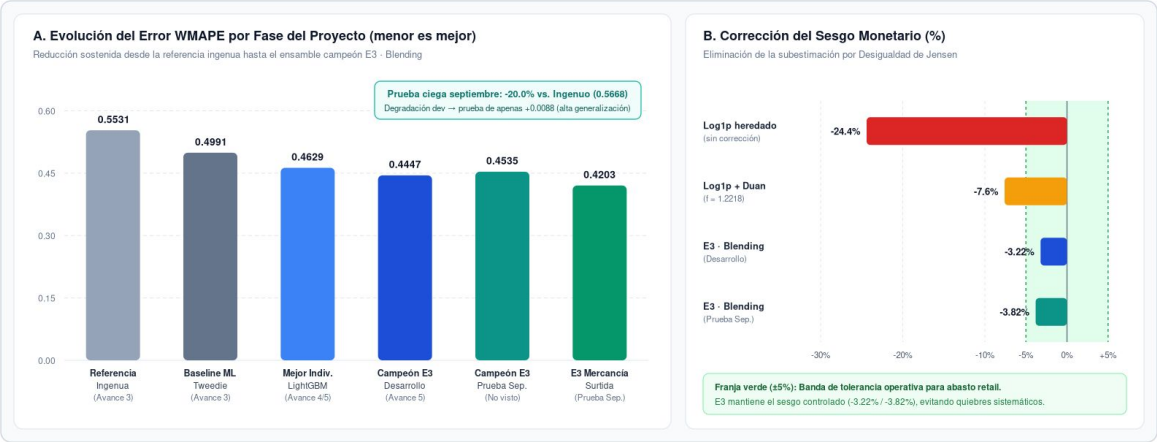
• Constraints Delta activos.

¿Por qué es crítica esta arquitectura para Tiendas SIX?

Elimina por diseño los rezagos móviles intra-ventana (como venta_lag_1 en T+h-1) que inflan artificialmente los backtests de laboratorio pero fallan en producción cuando los días intermedios aún no ocurren. Resultado auditado: 0 filas fuera de tolerancia temporal.

Esquema Unity Catalog: modeladoprescriptivoventas.maestria · Notebooks 02, 08, 09, 11, 13 y 20.

El ensamble E3 · Blending abate el WMAPE 20% en datos no vistos y corrige el sesgo monetario



Síntesis Cuantitativa Auditada (Desarrollo vs. Prueba No Vista)

- Referencia Ingenua: WMAPE 0.5531 (desarrollo, 4 cortes jun–ago) y 0.5668 (prueba septiembre).
- Mejor Modelo Individual (LightGBM Tweedie): WMAPE 0.4629 en el torneo formal de Avance 5.
- Ensamble Ganador E3 · Blending: WMAPE 0.4447 (dev) y 0.4535 (prueba) · Correlación de orden 0.92.
- Compuerta técnica aprobada (technical_pass = True) y 24 tablas publicadas en mlops_av5_*.

Claves de la Victoria de E3

- Torneo de 14 modelos:
  5 individuales, 3 homogéneos, 4 heterogéneos + ingenuo.
- Estabilidad líder:
  Desviación inter-corte de sólo 0.0023 (la menor de todo el torneo).
- Generalización limpia:
  De 0.4447 (desarrollo) a 0.4535 en septiembre no visto (+0.0088).
- Puntería en mercancía:
  WMAPE de 0.4203 en productos físicos surtibles.
- Sin sesgo de desabasto:
  -3.82% en prueba (dentro de ±5%).

Corrida formal Avance5.43 sobre tabla Oro v13 (marzo–septiembre) · Significancia Diebold–Mariano p < 0.05 en los 4 cortes de desarrollo.

Los intervalos conformales P10–P90 logran 82% de cobertura real y guían cada decisión operativa

P10 · Piso Conservador

• Escenario de demanda baja con 90% de probabilidad de ser superado.

• Uso en negocio:
- Estrés mínimo de flujo de caja.
- Control estricto de productos altamente perecederos o con alto riesgo de merma.
- Detección de caída abrupta si la venta real cae debajo de P10.

P50 · Pronóstico Central (Meta)

• Proyección mediana insesgada producida directamente por el ensamble E3 · Blending.

• Uso en negocio:
- Planeación financiera y cuota comercial por región y zona.
- Base de referencia para medir el uplift neto de escenarios promocionales What-If.
- Surtido regular en categorías estables.

P90 · Techo Seguro de Abasto

• Cota superior calibrada empíricamente con residuos fuera de muestra (Q_Conformal).

• Uso en negocio:
- Nivel objetivo de cobertura física (techo_unidades_p90_semana) en cervezas, refrescos y botanas.
- Blindaje contra quiebres de anaquel en quincenas, calor y fines de semana.

Ventaja de Q_Conformal frente a intervalos paramétricos teóricos

No asume normalidad ni simetría de errores: calibra los cuantiles directamente sobre errores reales fuera de muestra por horizonte h=1..14, logrando 82.0% de cobertura global observada (ancho relativo 0.84) sin subestimar la volatilidad de los días 8 al 14.

Banda nominal esperada: 80% (rango aceptable 75%–85%) · 14 de 14 horizontes diarios validados dentro de banda en Avance 5.

El sistema simula descuentos re-puntuando el modelo y desagrega la demanda a piezas por SKU

1. Calendario Editable (NB 13)

• Archivo único para el negocio: calendario_promociones_plan.xlsx.

• Captura simple de vigencia, alcance (nacional, región, zona o tienda) y descuento planeado.

• Si aún sólo se conocen fechas sin detalle, acepta categoria_id = TODAS e imputa descuento mediano histórico.

• Se sube al Volumen UC y surte efecto corriendo J2 → J4 sin tocar código ni reentrenar.

2. Simulador What-If ML (NB 30)

• Evalúa mallas de descuento comercial (-10%, -20%, -30%) modificando las variables futuras f_* del calendario.

• Re-puntúa cada escenario con los árboles entrenados del modelo campeón: el uplift proviene de patrones aprendidos, no de una elasticidad fija escrita a mano.

• Contrasta el resultado contra gold_uplift_promocional_historico como cota empírica.

3. Desagregación a SKU (NB 31)

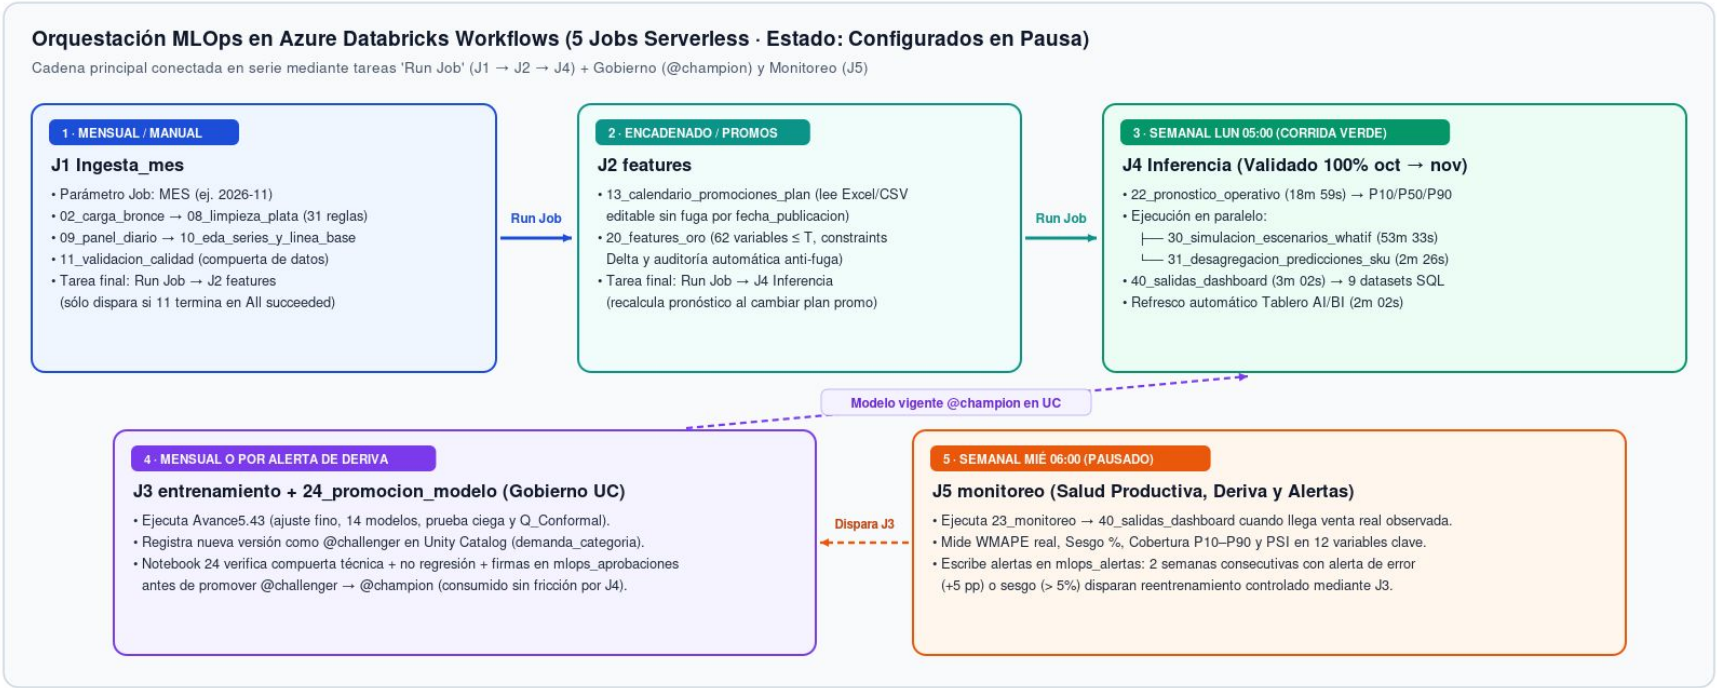
• Resuelve la inflación de ceros (>83%) repartiendo el pronóstico tienda × categoría mediante participaciones móviles de 28 días.

• Cubre el Top 15 SKUs por categoría + una fila explícita OTROS para reconciliación 100% aditiva.

• Entrega unidades semanales P50 y techo P90 listas para cruzar contra inventario en mano en ERP.

Notebooks productivos: 13_calendario_promociones_plan · 30_simulacion_escenarios_whatif · 31_desagregacion_predicciones_sku.

Cinco Jobs Serverless conectados con Run Job automatizan el flujo y hoy quedan en pausa segura



Ventaja clave: J4 corre solo cada lunes (sin disparar J1/J2), mientras que lanzar J1 encadena J1 → J2 → J4 automáticamente.

Workspace Bnext (externo1@bnext.mx) · J4 Inferencia ejecutado 100% en verde sobre cierre 2026-10-31 proyectando del 1 al 14 de noviembre.

El tablero nativo AI/BI organiza siete vistas según la pregunta de negocio de cada equipo



Regla de oro para leer el tablero:

1) Empezar en '7. Estado' (confirmar estado = ok y frescura) → 2) Revisar '1. Resumen' y '2. Pronóstico' (metas en P50) → 3) Bajar a '4. Surtido' (abasto en P90) y '5. Promociones' (What-If) → 4) Auditar '6. Alertas' y '3. Precisión'.

Tablero: mna_equipo43_demanda · 9 datasets SQL sobre SQL Warehouse Serverless · Latencia interactiva < 1 s sin exportar datos.

Cuatro reglas prácticas permiten convertir cada gráfica y tabla en decisiones operativas

A. Resumen y Pronóstico (Finanzas vs. Abasto)

• Usa venta_pronostico_14d (P50) para presupuesto comercial y metas regionales; compárala con variacion_vs_14d_previos.
• Filtra en cascada: región → zona → tipo_categoria → categoría → tienda.
• Distingue tipo_categoria = mercancia (productos físicos) de servicios/recargas.
• Una banda P10–P90 ancha señala alta volatilidad local.

B. Surtido por Producto SKU (Compras y CEDIS)

• Consulta Semana 1 (días 1–7) para despacho inmediato y Semana 2 (días 8–14) para pre-posicionamiento.
• unidades_p50_semana = venta esperada; techo_unidades_p90_semana = tope sugerido contra desabasto.
• La fila OTROS agrupa SKUs fuera del Top 15 para cuadrar el 100%.
• Pedido Neto = max(0, Techo P90 - Inventario en Mano).

C. Promociones y Simulador What-If (Trade Mkt)

• Verifica primero la columna fuente en Promociones: si dice 'placeholder' es plantilla demostrativa; las campañas reales dicen 'bnext'.
• En el comparador What-If, observa uplift_pesos y uplift_pct entre -10%, -20% y -30%.
• Si el uplift marginal se aplana entre -20% y -30%, un mayor descuento erosiona margen sin ganar volumen proporcional.

D. Precisión, Alertas y Estado (Control MLOps)

• En 'Estado', verifica cada lunes que origen, última venta y corridas marquen estado = ok.
• En 'Alertas', filtra severidad = alta: atiende tiendas con dias_inactiva_7d altos (posible falla POS) y caídas abruptas.
• En 'Precisión', vigila que WMAPE, sesgo (±5%) y cobertura (75–85%) permanezcan en verde.

Guía rápida de lectura para Dirección Comercial, Planeación de Abasto, Trade Marketing y Plataforma MLOps.

Tres procedimientos simples cubren toda la operación semanal, mensual y promocional

Caso 1 · Cada Semana (Rutina)

Objetivo: refrescar pronóstico de 14 días, surtido SKU y monitoreo.

Paso a paso:
1. Cuando Bnext active operación continua, cambiar de Paused a Active los schedules de:
   • J4 Inferencia (Lun 05:00)
   • J5 monitoreo (Mié 06:00)

2. Mientras sigan en pausa, basta entrar a J4 Inferencia y pulsar 'Run now' (sin parámetros).

3. En ~77 min el tablero AI/BI queda actualizado automáticamente.

Caso 2 · Llega Mes Nuevo (Parquet)

Objetivo: ingerir un nuevo cierre mensual y actualizar todo el sistema.

Paso a paso:
1. Subir Parquet del mes al Volumen de entrada e incluir el mes en MESES si amplía historia.

2. Abrir J1 Ingesta_mes → verificar parámetro MES = AAAA-MM (ej. 2026-11) → pulsar 'Run now'.

3. Automático: si 11_validacion_calidad aprueba, encadena Run Job → J2 features → Run Job → J4 Inferencia.

4. Al concluir, pulsar 'Run now' en J5 monitoreo para evaluar el mes.

Caso 3 · Cambia Plan de Promos

Objetivo: cargar campañas futuras sin reentrenar.

Campos clave (1 fila = promo × categoría × alcance):
• promo_id, inicio_planeado, fin_planeado (AAAA-MM-DD)
• categoria_id/nombre (o TODAS), descuento (0.15; 2x1=0.50),
  alcance (vacío=nacional), fecha_publicacion y fuente=bnext
  (eliminar filas placeholder).

2 vías de carga y ejecución:
• Vía A: subir Excel/CSV a /Volumes/.../outputs/calendario/.
• Vía B: conectar tabla/Parquet en MAPEO_COLUMNAS_BNEXT (NB 13).
• Pulsar Run now en J2 features (encadena J4 Inferencia).

No se requiere editar celdas de código para operar; todos los Jobs reciben configuración por parámetros o leen del Volumen UC.

El modelo sólo se reentrena por cierre mensual o alerta sostenida bajo esquema @challenger → @champion

Gobernanza MLOps: Semáforos Automáticos de Salud y Reglas de Reentrenamiento (Notebook 23 / Job J5)

Criterios cuantitativos auditados en producción para decidir cuándo mantener @champion vs. cuándo reentrenar en J3

Dimensión Vigilada	Parámetro / Métrica	Estado Sano (Verde)	Aviso / Alerta (Ámbar / Rojo)	Acción Operativa en Bnext
1. Precisión en Producción	UMBRAL_ERROR_PP = 0.05	WMAPE prod ≤ WMAPE dev + 5 pp	Supera en > 5.0 pp al desarrollo	2 semanas seguidas → Correr J3
2. Sesgo Monetario	UMBRAL_SESGO_PCT = 5.0%	|Sesgo %| ≤ 5.0% (-3.82% obs.)	|Sesgo %| > 5.0% (sobre/sub-abasto)	2 semanas seguidas → Correr J3
3. Calibración P10–P90	BANDA_COBERTURA (75–85%)	Cobertura real 75%–85% (82.0%)	Cobertura < 75% o > 85%	Recalibrar cuantiles en J3
4. Deriva de Variables	PSI en 12 vars (s_ma*, promo)	PSI ≤ 0.10 (distribución estable)	0.10 < PSI ≤ 0.20 Aviso | > 0.20 Alerta	Revisar cambio comercial / J3
5. Deriva de Contexto	t_ma28, tickets, zona, país	Cambio de media ≤ ±20%	Cambio de media > ±20% (56 días)	Inspeccionar aperturas/cierres
6. Frescura de Datos	DIAS_FRESCURA = 7 días	Última venta real ≤ 7 días	Retraso > 7 días sin ingesta	Cargar parquet y correr J1

Protocolo Seguro de Reentrenamiento en 4 Pasos (Sin Detener Producción):

1) Prueba opcional de humo (MODO_RAPIDO=True, 20 min) → 2) Ejecutar J3 entrenamiento (4–6 h): registra nueva versión como @challenger sin tocar @champion → 3) Ejecutar 24_promocion_modelo (ACCION=evaluar y luego promover) validando no regresión y firmas → 4) Correr J4 Inferencia.

Notebooks 23_monitoreo (Job J5) y 24_promocion_modelo · Rollback instantáneo en Unity Catalog reasignando alias @champion.

El sistema queda validado con octubre en verde y en pausa segura listo para activación

Lo que YA quedó ejecutado y verificado en Bnext

• Pipeline de datos (02 → 20) corrido hasta el cierre 2026-10-31 en modeladoprescriptivoventas.maestria.

• Job J4 Inferencia ejecutado 100% en verde en Serverless:
- 22_pronostico_operativo (18m 59s)
- 30_simulacion_escenarios_whatif (53m 33s)
- 31_desagregacion_predicciones_sku (2m 26s)
- 40_salidas_dashboard (3m 02s) + refresco AI/BI (2m 02s).

• Tablero mna_equipo43_demanda con sus 7 vistas pobladas proyectando del 2026-11-01 al 2026-11-14.

• Los 5 Jobs (J1..J5) configurados, conectados con Run Job (J1 → J2 → J4) y dejados en pausa.

Checklist para Activar Producción y Límites Declarados

1. Catálogo oficial de promociones: retirar filas placeholder y cargar plan real (fuente=bnext) vía Excel en outputs/calendario/ o tabla Delta con MAPEO_COLUMNAS_BNEXT en NB 13 (fijar FALLAR_SI_INVALIDO = True).

2. Antes de correr J2 o J3 por primera vez en Serverless, verificar sin comillas el %pip install en el panel Environment de NB 13 y Avance5.43 (pulsar Apply).

3. Definir DETENER_SI_FALLA = True en tarea 11 de J1 y otorgar permiso CREATE MODEL en UC para registrar el primer reentrenamiento con octubre.

4. Conectar existencias en tienda para pedido neto automático y exportar notebooks del workspace a Git.

Transparencia operativa: distinción clara entre componentes ya ejecutados con octubre y pasos previos a encender schedules.

Restricciones en Serverless vs. ruta de migración y ventajas en Clúster Dedicado



Arquitectura Híbrida Recomendada para Bnext (Cero Reescritura de Código):

Migrar los Jobs pesados (J1–J5) a Job Clusters efímeros con DBR 15.4 LTS ML (Driver 32–64 GB RAM + workers Azure Spot) elimina reinstalaciones %pip, multiplica por 2x–4x las filas de entrenamiento en memoria y recorta tiempos en 50%–75%; manteniendo el SQL Warehouse Serverless para consultas < 1 s en el tablero AI/BI.

Abstracción de cómputo en código: memoria_disponible_gb() (NIVEL_RAM = 16 / 32 / 64 GB), runtime_threads() y tabla(capa, nombre).

Tiendas SIX y Bnext cuentan hoy con una plataforma prescriptiva auditable, precisa y automatizada

1. Rigor Científico Comprobado

• Eliminación de fuga temporal en 62 variables y en calendario promocional.

• Corrección del sesgo de Jensen mediante E3 · Blending (+20.0% sobre ingenuo en prueba ciega y -3.82% de sesgo).

• Incertidumbre calibrada empíricamente al 82.0% con Q_Conformal.

2. Decisiones Accionables

• Traducción directa de pronósticos por categoría a unidades semanales P50 y techo P90 por SKU con reconciliación 100% aditiva.

• Simulación comercial What-If y captura de promociones en Excel sin depender de reentrenamientos.

• 7 vistas ejecutivas en < 1 segundo.

3. MLOps Gobernado y Listo

• Inferencia desacoplada y paralelizada en Databricks Workflows Serverless.

• Vigilancia automática de error, sesgo, cobertura y deriva PSI.

• Promoción segura @challenger → @champion con trazabilidad total dentro de Unity Catalog.

Equipo 43 · Daniela Juárez Ortiz · Kevin Alexis Valdez Pérez · Yael Ariel Márquez Mas

Gracias al equipo directivo y técnico de Tiendas SIX / Bnext, al Dr. Juan Arturo Nolazco Flores y a la Dra. Eduviges Ludivina Facundo por su acompañamiento durante el Proyecto Integrador.