

Tecnológico de Monterrey · Escuela de Ingeniería y Ciencias
Maestría en Inteligencia Artificial Aplicada (MNA) · Proyecto Integrador

Reporte Final y Manual de Operación MLOps: Pronóstico Probabilístico de Demanda, Simulación Prescriptiva y Desagregación por SKU para Tiendas SIX (Bnext)

Entrega Final Integradora (Semanas 1 a 8 · Avances 0 al 6)

- **Equipo 43:** Daniela Juárez Ortiz (`A01797369`) · Kevin Alexis Valdez Pérez (`A01750478`) · Yael Ariel Márquez Mas (`A01745310`)
- **Organización Beneficiaria y Socio Formador:** Tiendas SIX (~17,000 tiendas de conveniencia en México) \& Bnext
- **Patrocinador Institucional:** Dr. Juan Arturo Nolazco Flores — Director del Hub de Ciencia de Datos
- **Asesora Académica:** Dra. Eduviges Ludivina Facundo

- **Plataforma Productiva:** Azure Databricks Serverless · Unity Catalog (`modeladoprescriptivoventas.maestria`)
- **Fecha de Cierre:** Noviembre de 2026

1. Resumen Ejecutivo Integral y Valor de Negocio

El presente documento constituye el **Reporte Final y Manual de Transferencia Operativa (Runbook)** del Proyecto Integrador desarrollado por el **Equipo 43** para **Tiendas SIX y Bnext**. A lo largo de ocho semanas y seis avances incrementales bajo la metodología **CRISP-ML(Q)**, el proyecto evolucionó desde la auditoría y saneamiento de datos crudos de punto de venta hasta un **sistema prescriptivo de pronóstico y reabastecimiento completamente industrializado bajo prácticas MLOps en Azure Databricks**.

El problema central de negocio consiste en anticipar diariamente la demanda en pesos mexicanos y unidades físicas para cada combinación **tienda × categoría** (y su reparto operativo a nivel **producto/SKU**) en un horizonte deslizante de **14 días** (h = 1, ..., 14),

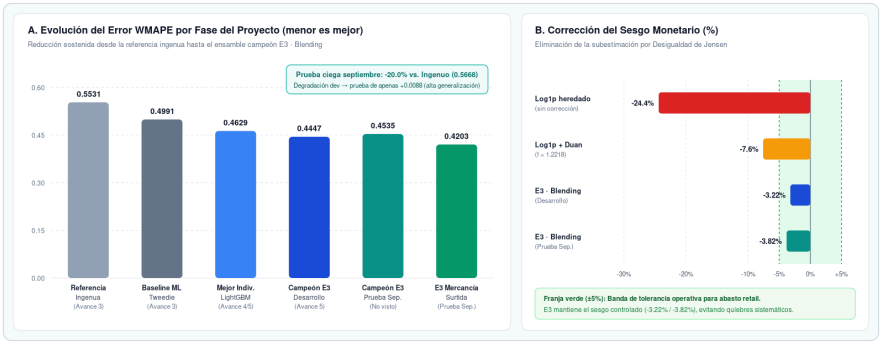
utilizando exclusivamente información disponible hasta la fecha de corte T. En una red de ~17,000 tiendas de conveniencia, subestimar sistemáticamente la demanda provoca **quiebres de anaquel** y pérdida directa de ingresos en categorías de alta rotación (cervezas, refrescos, botanas), mientras que sobrestimar inmoviliza capital de trabajo y eleva mermas.

Dimensión del Sistema	Resultado Auditado y Entregado	Impacto Técnico y de Negocio
Arquitectura de Datos	Medallón en Unity Catalog (`bronze_*`, `silver_*`, `gold_*`, `mlops_*`) con **25 notebooks** parametrizados	Gobernanza extremo a extremo sin que los datos privados salgan de Databricks (`MODO_PUBLICO = True`).
Blindaje Anti-Fuga	**62 variables predictoras** estrictamente ancladas en ≤ T + promociones regidas por `fecha_publicacion`	**0 filas con fuga temporal** en auditoría automática; métricas 100% reproducibles en operación real.
Modelo Campeón (`Avance 5`)	Ensamble heterogéneo convexo **`E3 · Blending`** seleccionado entre 14 formulaciones	**WMAPE desarrollo `0.4447`** (`+19.6%` vs. ingenuo `0.5531`) y **prueba ciega septiembre `0.4535`** (`+20.0%` vs. `0.5668`).
Control de Sesgo y Mercancía	Sesgo monetario **`-3.22%`** (desarrollo) y **`-3.82%`** (prueba); WMAPE mercancía física **`0.4203`**	Elimina la severa subestimación del enfoque heredado `Log1p` (`-24.4%` por desigualdad de Jensen) dentro del margen seguro `±5%`.
Incertidumbre Calibrada	Intervalos conformales **`Q_Conformal`** (`P10`, `P50`, `P90`) con **cobertura empírica global `82.0%`**	`14 de 14` horizontes dentro de la banda `75%–85%`; habilita metas financieras (`P50`) y techos seguros de inventario (`P90`).
Prescripción Comercial y SKU	Calendario promocional editable en Excel (`13`), What-If con re-puntuación ML (`30`) y reparto SKU + `OTROS` (`31`)	Reconciliación matemática **100% aditiva** tienda × categoría × semana y simulación de descuentos sin reentrenar.
Orquestación Automatizada	**5 Jobs Serverless** (`J1` a `J5`) encadenados con `Run Job` (`J1 → J2 → J4`) y puestos en pausa segura	**`J4 Inferencia` validado 100% en verde** con cierre al `2026-10-31` proyectando del `2026-11-01` al `2026-11-14`.
Producto de Difusión	Tablero nativo **Databricks AI/BI (`mna_equipo43_demanda`)** con **7 vistas** y **9 datasets SQL**	Consulta interactiva en `< 1 s` sobre SQL Warehouse Serverless para Dirección, Abasto, Trade Marketing y MLOps.

Importante: Logro clave de industrialización: En las fases de investigación reentrenar y evaluar tomaba entre **4 y 6 horas**. Al desacoplar la inferencia operativa (`22_pronostico_operativo`) del entrenamiento (`Avance5.43`), la actualización completa de pronósticos, escenarios What-If en paralelo, surtido SKU y refresco del tablero (`J4 Inferencia`) finaliza de extremo a extremo en **~77 minutos totales de reloj** (con el pronóstico base listo en **19 minutos**).

2. Resumen Cronológico de las Fases Realizadas (Semanas 1 a 8)

El proyecto se estructuró en seis fases progresivas donde cada entregable resolvió las limitaciones empíricas detectadas en la etapa inmediata anterior, manteniendo trazabilidad completa en tablas Delta y MLflow.



2.1 Síntesis Ejecutiva Fase por Fase

La siguiente matriz resume la progresión técnica desde la ingesta inicial en Bronce hasta la puesta en operación del sistema MLOps completo, vinculando cada entregable semanal con su impacto cuantitativo verificado en el catálogo de producción:

Fase / Semana	Entregable / Avance	Trabajo Técnico Realizado	Hito / Resultado Verificado
Fase 0–1 · *(Semanas 1–3)*	**Planteamiento, Convenios, Bronce y EDA** *(Avances 0 y 1)*	Definición de objetivos CRISP-ML(Q), inventario de volúmenes en Unity Catalog (`00`, `01`), ingesta trazable de archivos Parquet mensuales a Bronce (`02_carga_bronce`) y diagnóstico exploratorio de calidad, estacionalidad, promociones y fuentes externas (`04` a `07`).	Identificación de inflado de ceros (`>52%` a nivel categoría y `>83%` en SKU directo), devoluciones, duplicados entre cierres mensuales y huecos postales en variables exógenas.
Fase 2 · *(Semana 4)*	**Limpieza Plata e Ingeniería de Características Oro** *(Avance 2)*	Implementación de **31 reglas de limpieza y homologación** en `08_limpieza_plata`, construcción del panel continuo diario con ceros explícitos en tiendas activas (`09_panel_diario`), rescate postal INEGI/SEPOMEX y diseño de la tabla `gold_features_origen` (`20_features_oro`).	**62 variables sin fuga** ancladas estrictamente en $\leq T$ (estado congelado en T, rezagos del mismo día de semana $T+h-7k \leq T$, contexto zonal y calendario *ex-ante*); **0 registros con fuga** en `257,364` filas auditadas.
Fase 3 · *(Semana 5)*	**Línea Base, Walk-Forward y Sesgo de Jensen** *(Avance 3)*	Instrumentación de validación *walk-forward* multi-ventana a 14 días (`10_eda_series_y_linea_base`) y escalera de 4 modelos base: Naive estacional (`lag_7`), Media Móvil 7d, LightGBM `Log1p` heredado y nuevo LightGBM `Tweedie` (ρ=1.5).	Demostración matemática de que invertir log(1+y) con exp(ŷ)-1 introduce **-24.4% a -35.9% de subestimación** por Desigualdad de Jensen; Tweedie abate el WMAPE inicial de `0.5815` (Naive) a **`0.4991`** con brecha train-val de solo `2.34 pts`.
Fase 4 · *(Semana 6)*	**Torneo de Modelos Individuales y Explicabilidad** *(Avance 4)*	Ejecución completa de `21_avance4_modelos_alternativos` evaluando **10 modelos** en muestra común (`18,798` series) y universo completo (**`30,471,370` filas**), optimización bayesiana con Optuna, curvas de aprendizaje y auditoría `Gain %` vs. `Splits %` vs. `SHAP %`.	`M4_lightgbm` (Tweedie ajustado) alcanza **WMAPE `0.4503`** (muestra) y **`0.4562`** (universo), sesgo `-0.1%`, menor RMSE y registro de la **Versión 1** en Unity Catalog (`demanda_categoria`).

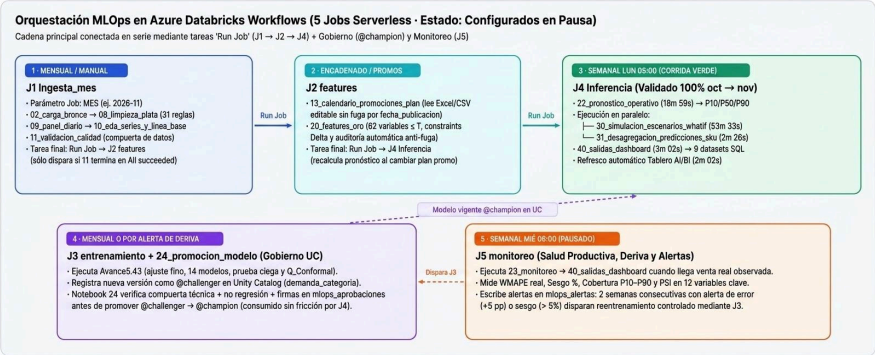
Fase / Semana	Entregable / Avance	Trabajo Técnico Realizado	Hito / Resultado Verificado
Fase 5 · *(Semana 7)*	**Ensambles, Prueba No Vista e Incertidumbre** *(Avance 5)*	Corrida formal de `Avance5.43` sobre tabla Oro v13 (7 meses: marzo a septiembre), comparando 5 modelos individuales, 3 ensambles homogéneos y 4 heterogéneos en 4 cortes de desarrollo (junio–agosto) y prueba ciega en septiembre.	Victoria de **`E3 · Blending`**: WMAPE desarrollo **`0.4447`** (`+19.6%` vs. ingenuo, desviación mínima `0.0023`), WMAPE prueba ciega **`0.4535`** (`+20.0%` vs. `0.5668`), Diebold–Mariano p < 0.05 en 4/4 cortes y cobertura conformal **`82.0%`**.
Fase 6 · *(Semana 8)*	**Operación MLOps, Escenarios, Surtido SKU y Tablero AI/BI** *(Avance 6)*	Desacoplamiento de inferencia (`22`), calendario promocional Excel (`13`), What-If ML (`30`), reparto SKU con fila `OTROS` (`31`), monitoreo y alertas (`23`), promoción `@champion` (`24`), salidas SQL (`40`), 5 Jobs Workflows y tablero AI/BI de 7 vistas.	Carga e ingeniería hasta **`2026-10-31`**, corrida **`J4 Inferencia`** **100% exitosa en Serverless** (horizonte `1–14 nov 2026`), 7 vistas del tablero pobladas y 5 Jobs encadenados con `Run Job` listos en pausa.

2.2 Lecciones Técnicas Clave que Sostienen la Solución Final

1. **Optimización directa en escala natural vs. transformación logarítmica:** En series comerciales diarias con 60%–65% de ceros y colas derechas pronunciadas en fines de semana y quincenas, entrenar árboles con pérdida Tweedie (ρ = 1.5) y combinación convexa (`E3 · Blending`) preserva la escala monetaria sin requerir factores de corrección post-hoc como Duan (f = 1.2218) y mantiene el sesgo dentro de `±5%`.
2. **Desagregación jerárquica *Top-Down* frente a modelado SKU directo:** Modelar directamente cada SKU multiplica la proporción de ceros por encima del 83% y degrada la estabilidad estadística. Pronosticar primero la demanda agregada de **tienda × categoría** (donde la señal promocional y estacional es limpia) y repartirla mediante participaciones móviles de 28 días sobre los **Top 15 SKUs + una fila explícita `OTROS`** garantiza **100% de reconciliación aditiva** sin perder ni un peso de venta proyectada.
3. **Promociones futuras sin fuga de información:** El módulo `13_calendario_promociones_plan` incorpora el atributo `fecha_publicacion`: en cualquier corte histórico o productivo T, el modelo únicamente observa promociones cuyo plan ya había sido publicado en o antes de T, asegurando honestidad experimental absoluta entre backtesting y producción.

3. Arquitectura Automatizada en Azure Databricks Workflows

Toda la solución vive y se ejecuta dentro del workspace corporativo de Azure Databricks bajo el esquema **`modeladoprescriptivoventas.maestria`** en Unity Catalog, organizada en cuatro dominios de tablas Delta (`bronze_*`, `silver_*`, `gold_*` y `mlops_*`) y tres carpetas modulares de código (`1_datos`, `2_modelos`, `3_operacion`).



3.1 Estructura de los 5 Jobs Configurados y su Encadenamiento (Run Job)

Para operar sin depender de intervención manual entre etapas y sin requerir permisos administrativos externos de *File Arrival*, los cinco flujos de trabajo fueron creados en **Jobs & Pipelines** sobre cómputo **Serverless** y conectados en serie mediante tareas nativas de tipo **Run Job**:

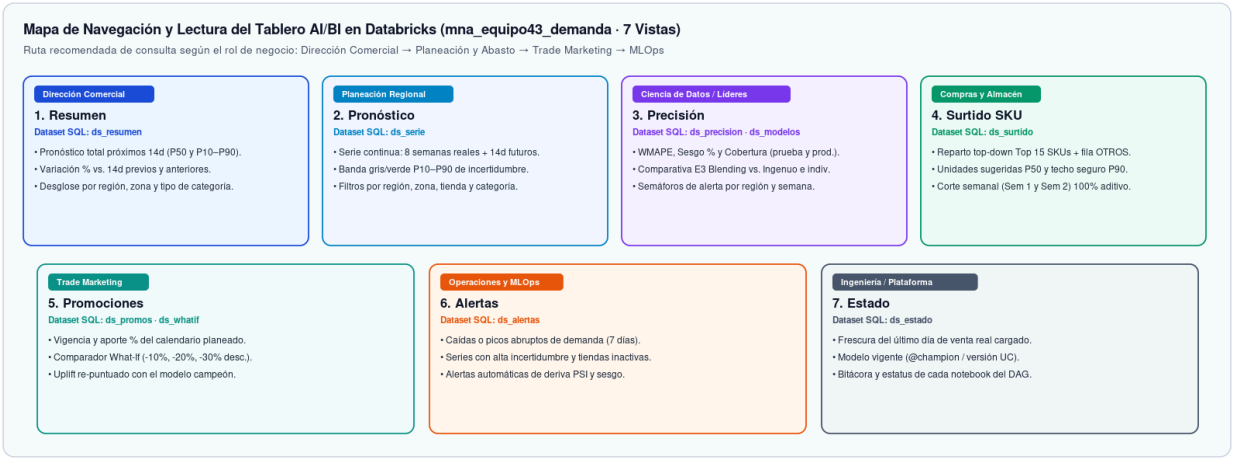
Job en Databricks UI	Tareas Internas y Orden de Ejecución (DAG)	Encadenamiento Automático (Run Job)	Cadencia Objetivo y Estado Actual
J1 Ingesta_mes	Parámetro Job `MES` (`2026-11`): `02_carga_bronce` → `08_limpieza_plata` → `09_panel_diario` → `10_eda_series_y_linea_base` → `11_validacion_calidad`	`disparar_j2_features` (`Type: Run Job` → **J2 features**, `Depends on: 11_validacion_calidad`, condición `All succeeded`)	**Mensual / Manual** al recibir nuevo corte Parquet. Trigger actual: **None (Pausado)**.
J2 features	`13_calendario_promociones_plan` → `20_features_oro` (reconstruye variables ≤ T, valida constraints y prueba anti-fuga)	`disparar_j4_inferencia` (`Type: Run Job` → **J4 Inferencia**, `Depends on: 20_features_oro`, condición `All succeeded`)	**Automático tras J1** o manual al actualizar el Excel de promociones. Trigger actual: **None (Pausado)**.
J3 entrenamiento	`Avance5.43` (`MODO_RAPIDO=False`, `REENTRENAR_FINAL=True`, `USAR_CALENDARIO_PROMOS=True`, `INCLUIR_Q_LIGHTGBM=True`, `MODO_PUBLICO=True`)	Desacoplado a propósito: registra versión `@challenger` para revisión en `24_promocion_modelo` antes de tocar `@champion`.	**Mensual / Bimestral o por Alerta**. Trigger actual: **None (Pausado)**.
J4 Inferencia	`22_pronostico_operativo` (`18m 59s`) → en paralelo `[30_simulacion_escenarios_whatif (53m 33s)	31_desagregacion_predicciones_sku (2m 26s)]` → `40_salidas_dashboard` (`3m 02s`) → `refresco` dashboard (`2m 02s`)		
J5 monitoreo	`23_monitoreo` → `40_salidas_dashboard` (actualiza vistas de Precisión, Alertas y Estado con métricas reales de producción)	Independiente; si acumula 2 semanas con alerta de error o sesgo, instruye ejecutar `J3 entrenamiento`.	**Semanal (Miércoles 06:00 CST)**. Schedule actual: **Paused**.

3.2 ¿Por qué esta Topología es Segura y Eficiente?

1. **Compuerta automática de calidad antes de recalcular características:** En `J1_Ingesta_mes`, la tarea `disparar_j2_features` exige `All succeeded` sobre `11_validacion_calidad`. Cuando el parámetro `DETENER_SI_FALLA = True` está activo en producción, cualquier anomalía crítica en el archivo mensual aborta la cadena en `J1` e impide contaminar la tabla Oro y el pronóstico vigente.
2. **Doble vía de ejecución sin duplicar Jobs:** Si llega un mes nuevo y se lanza `J1`, el sistema corre en serie **`J1 → J2 → J4`**. Si solo cambia el archivo Excel de promociones y se lanza `J2`, corre **`J2 → J4`**. Y en una semana ordinaria donde solo se refresca la ventana operativa, el schedule de `J4` ejecuta **únicamente `J4`** en ~77 minutos.
3. **Paralelismo real en `J4_Inferencia`:** Una vez que `22_pronostico_operativo` deposita `gold_pronostico_14d`, las tareas `30_simulacion_escenarios_whatif` (que re-puntúa múltiples mallas de descuento con los árboles del modelo) y `31_desagregacion_predicciones_sku` corren simultáneamente; al concluir ambas, `40_salidas_dashboard` consolida las nueve vistas SQL y refresca automáticamente el tablero AI/BI `mna_equipo43_demanda`.

4. Guía Completa: Cómo Leer e Interpretar el Dashboard AI/BI (`mna_equipo43_demanda`)

El tablero ejecutivo **`mna_equipo43_demanda`** está construido de forma nativa en **Databricks AI/BI Dashboards** sobre un **SQL Warehouse Serverless**. No exporta datos fuera del entorno gobernado de Bnext y responde en tiempo interactivo sobre las tablas precalculadas `gold_dash_*`, `gold_surtido_sku_semana` y `gold_escenarios_whatif_resumen`.



4.1 Conceptos Clave para Interpretar las Cifras del Tablero

Antes de recorrer cada pestaña, todo usuario de negocio debe tener presentes cuatro reglas de lectura:

- **Pronóstico Central (`P50` / `venta_pronostico_14d`):** Es la proyección mediana esperada en condiciones del plan vigente. Debe utilizarse para **presupuesto comercial, flujo de caja y metas de venta** porque equilibra el riesgo de sobrestimar y subestimar.
- **Banda de Incertidumbre (`P10` a `P90`):** Generada mediante calibración conformal (`Q_Conformal`) con una cobertura empírica auditada del **82.0%**. `P10` representa el escenario conservador (piso de demanda) y **`P90` representa el techo operativo de seguridad**: abastecer mercancía perecedera cerca de `P50` y mercancía seca de alta rotación/margen hacia `P90` protege contra quiebres de inventario en picos de fin de semana o quincena.
- **Horizonte Activo (`origen`, `desde`, `hasta`):** En la corrida validada actual, `origen = 2026-10-31`, cubriendo los 14 días comprendidos entre `desde = 2026-11-01` y `hasta = 2026-11-14`.
- **Unidades `P50` vs. Techo `P90` y fila `OTROS` en Surtido:** En la pestaña de surtido, cada tienda × categoría muestra sus **15 SKUs líderes** ordenados por participación de los últimos 28 días (`rank_sku = 1..15`) más un registro integrador **`OTROS`** que concentra la cola larga de productos menores, asegurando que la suma de unidades y pesos coincida exactamente al 100% con el pronóstico de la categoría.

4.2 Lectura Detallada Pestaña por Pestaña (Las 7 Vistas)

Vista 1 · `Resumen` *(Dirección Comercial y Planeación General)*

- **Pregunta que responde:** *¿Cuánto esperamos vender en los próximos 14 días en toda la red y cómo se compara contra las cuatro semanas previas?*
- **Fuente SQL:** `ds_resumen` (`gold_dash_resumen_ejecutivo`).
- **Cómo leerla:**
  1. Revisa primero los **KPIs superiores** a `nivel = total`: muestran la venta proyectada a 14 días (`venta_pronostico_14d`), el rango `p10_14d – p90_14d`, el número de tiendas y series activas, y la **variación porcentual contra los 14 días inmediatos anteriores** (`variacion_vs_14d_previos`).
  2. Analiza las gráficas de barras por **`region`** y **`tipo_categoria`** (`mercancia` vs. servicios/recargas): permiten distinguir si el crecimiento proviene de categorías físicas surtibles en camión o de categorías electrónicas.
  3. Observa `ancho_relativo_banda` y `pct_filas_con_promo_planeada`: una región con banda ancha tiene mayor volatilidad reciente y requiere vigilancia más estrecha de stock de seguridad.

Vista 2 · `Pronóstico` *(Gerentes Regionales, Zonales y Planeadores de Demanda)*

- **Pregunta que responde:** *¿Cuál es la trayectoria diaria exacta de una región, zona, categoría o tienda específica uniendo las últimas 8 semanas reales con los próximos 14 días?*
- **Fuente SQL:** `ds_serie` (`gold_dash_serie_tiempo`).
- **Cómo leerla:**
  1. Usa los filtros en cascada de arriba hacia abajo: **`region`** → **`zona`** → **`tipo_categoria`** → **`categoria_nombre`** → **`tienda`**.
  2. En la curva temporal, la serie cambia de color por `tipo_dato`: el tramo histórico (`real`) muestra el pulso semanal observado (picos de viernes-domingo y quincenas) y el tramo futuro (`pronostico`) proyecta los 14 días siguientes acompañado de sus cotas `p10` y `p90`.
  3. Si el pronóstico futuro rompe abruptamente el patrón de las 8 semanas previas, verifica el indicador `pct_series_con_promo` para confirmar si obedece a una promoción activa o a una alerta operativa.

Vista 3 · `Precisión` *(Ciencia de Datos, Finanzas y Patrocinadores)*

- **Pregunta que responde:** *¿Qué tan confiable es el modelo campeón frente al método ingenuo y frente a los demás algoritmos evaluados, tanto en prueba ciega como en producción?*
- **Fuentes SQL:** `ds_precision` (`gold_dash_precision`) y `ds_modelos` (`gold_dash_precision_modelos`).
- **Cómo leerla:**
  1. Filtra por `fase` (`prueba` corresponde a los bloques ciegos auditados; `produccion` se alimenta conforme `23_monitoreo` cruza pronósticos guardados contra ventas reales nuevas).
  2. Revisa tres métricas conjuntas: **`wmape`** (error relativo ponderado por venta; menor es mejor, p. ej. `0.4535` vs. `0.5668` del ingenuo), **`sesgo_pct`** (ideal entre `-5%` y `+5%`; negativo indica ligera subestimación, positivo indica sobrestimación) y **`cobertura`** (porcentaje de días reales que cayeron dentro de `[P10, P90]`; saludable entre `75%` y `85%`).
  3. En la tabla comparativa `ds_modelos`, contrasta `E3 · Blending` contra los modelos individuales y ensambles alternativos, observando especialmente `wmape_mercancia` (`0.4203`), que mide la puntería en productos físicos inventariables.

Vista 4 · `Surtido` *(Compras, Abasto, CEDIS y Operación en Tienda)*

- **Pregunta que responde:** *¿Cuántas unidades físicas de cada SKU debemos preparar esta semana (`Semana 1`) y la próxima (`Semana 2`) en cada tienda?*
- **Fuente SQL:** `ds_surtido` (`gold_surtido_sku_semana` enriquecida con `silver_catalogo_categorias`).
- **Cómo leerla:**

1. Filtra la `region`, `tienda`, `categoria_nombre` y `semana_horizonte` (`1` para los días 1 a 7, `2` para los días 8 a 14).
2. Lee las columnas operativas clave por `producto_id`:
    - `rank_sku` y `share_venta`: importancia del SKU dentro de esa categoría en esa tienda durante los últimos 28 días.
    - `unidades_p50_semana`: **demanda base esperada en piezas físicas** para una semana normal.
    - `techo_unidades_p90_semana`: **nivel máximo recomendado de cobertura** para evitar desabasto ante picos de demanda.
3. **Advertencia operativa esencial:** Como Bnext aún no integra saldos de inventario en mano dentro de Databricks, `techo_unidades_p90_semana` es el **requerimiento bruto de demanda**, por lo que el pedido neto a despachar en ERP se obtiene restando la existencia actual en tienda: Pedido Neto = max(0, Techo Unidades P90 - Inventario Actual).

Vista 5 · `Promociones` *(Trade Marketing y Estrategia Comercial)*

- **Pregunta que responde:** *¿Qué campañas promocionales están programadas en el horizonte actual y cuánto subiría la venta si modificamos la profundidad de descuento (-10%, -20%, -30%)?*
- **Fuentes SQL:** `ds_promos` (`gold_dash_promociones`) y `ds_whatif` (`gold_escenarios_whatif_resumen`).
- **Cómo leerla:**
    1. En la tabla superior (`ds_promos`), verifica la columna **`fuente`**: si dice `placeholder`, las promociones mostradas provienen de la plantilla demostrativa y deben sustituirse por el plan oficial (`fuente = bnext`). Revisa `en_horizonte`, `dias_para_inicio` y `aporte_plan_pct`.
    2. En el comparador **What-If (`ds_whatif`)**, compara el escenario base contra los escenarios de descuento (`10%`, `20%`, `30%`). A diferencia de simuladores estáticos por regla de tres, aquí `venta_escenario`, `uplift_pesos` y `uplift_pct` provienen de **modificar las variables promocionales `f_*` y volver a puntuar el modelo de Machine Learning**, capturando no linealidades por región y categoría.

Vista 6 · `Alertas` *(Torre de Control Operativa y Equipo MLOps)*

- **Pregunta que responde:** *¿Dónde hay anomalías comerciales hoy (caídas bruscas, alta incertidumbre, tiendas sin reportar ventas) o alertas de degradación del modelo?*
- **Fuente SQL:** `ds_alertas` (`gold_dash_alertas`).
- **Cómo leerla:**
    1. Filtra primero por `severidad = alta` y distingue la columna `fuente`: las alertas de **negocio/series** señalan combinaciones tienda × categoría con variaciones extremas (`cambio_7d`), bandas de incertidumbre inusualmente amplias (`incertidumbre`) o tiendas con varios días sin actividad

(`dias_inactiva_7d`, útil para detectar cierres temporales o fallas de transmisión POS).
2. Las alertas de **monitoreo MLOps** provienen de `23_monitoreo` e indican desvíos en WMAPE, sesgo, cobertura o deriva `PSI`.

Vista 7 · `Estado` *(Ingeniería de Datos, Gobierno y Auditoría)*

- **Pregunta que responde:** *¿Con qué corte de datos estamos trabajando hoy, qué modelo está activo y cuándo corrió por última vez cada eslabón del pipeline?*
- **Fuente SQL:** `ds_estado` (`gold_dash_estado_pipeline`).
- **Cómo leerla:**
  1. Antes de tomar decisiones ejecutivas los lunes por la mañana, confirma en `tb_estado` que todos los indicadores clave tengan `estado = ok`: fecha máxima de venta real cargada, origen del pronóstico vigente, versión/alias del modelo utilizado y marca de tiempo (`fecha_calculo`) de la última ejecución exitosa de `02`, `08`, `09`, `20`, `22`, `30`, `31` y `40`.

5. Manual Paso a Paso de Ejecución Operativa (Runbook para Bnext)

Actualmente los **5 Jobs se encuentran configurados, encadenados y dejados intencionalmente en pausa (`Paused` / `None`)** para que no consuman cómputo automático sin autorización explícita de Bnext. A continuación se detalla qué debe hacer el equipo técnico y comercial en cada situación real.

5.1 Checklist Único Antes de Pasar de "Pausa" a Operación Viva

1. **Verificar librerías sin comillas en el entorno Serverless de `J2` y `J3`:** En los jobs `J4 Inferencia` (`22` y `30`) ya se limpió la sintaxis de `%pip install` en Serverless. Antes de lanzar por primera vez `J2 features` o `J3 entrenamiento`, abrir en el Workspace los notebooks `1_datos/13_calendario_promociones_plan` y `2_modelos/Avance5.43`, confirmar que ninguna línea `%pip install` ni el panel lateral **Environment** contenga comillas dobles (ej. usar `openpyxl>=3.1,<4` sin `"..."`) y pulsar **Apply**.
2. **Activar el freno estricto de calidad en `J1 Ingesta_mes` (recomendado en producción):** En la tarea `11_validacion_calidad` de `J1`, agregar el parámetro `DETENER_SI_FALLA` con valor `True` para que cualquier error crítico en un Parquet mensual nuevo detenga el flujo antes de invocar `Run Job → J2 features`.
3. **Confirmar privilegios de Unity Catalog para registro de nuevas versiones:** Para que `J3 entrenamiento` y `24_promocion_modelo` registren y promuevan versiones directamente en `modeladoprescriptivoventas.maestria.demanda_categoria`, el usuario o *Service Principal* ejecutor (`Run as`) debe contar con `USE CATALOG`, `USE SCHEMA`, `SELECT`, `MODIFY` y `CREATE MODEL` sobre el esquema `maestria`.
4. **Despausar los dos triggers semanales cuando Bnext decida iniciar operación continua:**

- Entrar a **J4 Inferencia** → panel derecho **Schedules & Triggers** → cambiar de Paused a **Active** (Lunes 05:00 CST).
- Entrar a **J5 monitoreo** → panel derecho **Schedules & Triggers** → cambiar de Paused a **Active** (Miércoles 06:00 CST).
- Dejar **J1 Ingesta_mes**, **J2 features** y **J3 entrenamiento** con trigger **None** (se disparan bajo demanda o por encadenamiento Run Job).

5.2 Escenario A · Operación Semanal Ordinaria (Cada Semana)

- **¿Qué hace el usuario?** Nada si los schedules de J4 y J5 están activos; o bien, si siguen en pausa, entrar a **J4 Inferencia** y pulsar **Run now** (no requiere llenar parámetros).
- **¿Qué ocurre automáticamente?**
  1. 22_pronostico_operativo carga el modelo vigente (@champion), toma el corte más reciente de la tabla Oro y escribe gold_pronostico_14d (P10, P50, P90).
  2. En paralelo corren 30_simulacion_escenarios_whatif y 31_desagregacion_predicciones_sku.
  3. 40_salidas_dashboard actualiza las tablas gold_dash_* y la tarea final dashboard refresca el tablero mna_equipo43_demanda.
  4. Los miércoles, **J5 monitoreo** cruza los pronósticos previos contra las ventas reales recién observadas y actualiza la salud del sistema.

5.3 Escenario B · Llegada de un Nuevo Mes de Ventas (Cierre Mensual Paso a Paso)

Cuando Bnext deposita los archivos Parquet de un mes cerrado nuevo (por ejemplo 2026-11):

1. **Verificar archivo fuente en el Volumen:** Confirmar que los Parquet del mes estén cargados en el volumen de entrada correspondiente dentro de Unity Catalog (puede verificarse corriendo 1_datos/01_inventario_catalogo).
2. **Actualizar la lista maestra MESES si se incorpora un mes nuevo al horizonte histórico:** En la configuración común de los notebooks (MESES = ["2026-03", ..., "2026-11"]), incluir el nuevo mes para que el panel Plata y la tabla Oro lo abarquen íntegramente.
3. **Ejecutar J1 Ingesta_mes:**
   - Ir a **Jobs & Pipelines** → **J1 Ingesta_mes** → clic en **Run now** (o *Run now with different parameters*).
   - Verificar que el parámetro de Job **MES** tenga el formato AAAA-MM del mes a cargar (p. ej. 2026-11).
4. **Flujo automático en cadena (J1 → J2 → J4):**

- J1 ejecuta 02_carga_bronce → 08_limpieza_plata → 09_panel_diario → 10_eda_series_y_linea_base → 11_validacion_calidad.
- Al terminar 11_validacion_calidad sin fallos críticos, la tarea disparar_j2_features lanza automáticamente **J2 features** (13_calendario_promociones_plan → 20_features_oro).
- Al terminar 20_features_oro, la tarea disparar_j4_inferencia lanza automáticamente **J4 Inferencia** (22 → 30 || 31 → 40 → dashboard).

5. **Cerrar la evaluación del mes entrante con J5 monitoreo:** Una vez concluido J4, ejecutar **J5 monitoreo** (Run now) para calcular el WMAPE real, sesgo, cobertura y deriva PSI del mes recién incorporado y revisar la pestaña **6. Alertas** del tablero.

5.4 Escenario C · Actualización del Calendario de Promociones Planeadas (Sin Reentrenar)

Cada vez que Trade Marketing defina o modifique campañas futuras, **no se necesita tocar código ni reentrenar el modelo**:

1. Abrir el archivo editable **calendario_promociones_plan.xlsx** (hoja promociones), **eliminar las filas demostrativas con fuente = placeholder** y dejar únicamente promociones reales con **fuente = bnext**.
2. Capturar una fila por **promoción × categoría × alcance** siguiendo el contrato de la Sección 5.5.
3. Subir y reemplazar el archivo en Unity Catalog: **Catalog** → **modeladoprescriptivoventas** → **maestria** → **Volumes** → **outputs** → **calendario** → **Upload**.
4. Ir a **Jobs & Pipelines** → **J2 features** → clic en **Run now**:
    a. 13_calendario_promociones_plan validará el archivo, registrará su huella SHA-256 en mlops_calendario_plan_versiones y actualizará silver_calendario_promociones_plan[_dia].
    b. 20_features_oro actualizará las variables futuras f_* del origen activo.
    c. La tarea Run Job al final de J2 disparará automáticamente **J4 Inferencia**, refrescando el pronóstico, el simulador What-If, el surtido SKU y el tablero AI/BI con el nuevo plan comercial.

5.5 Nota Técnica para Bnext: Qué Debe Incluir y Cómo Cargar su Catálogo Oficial de Promociones

Para que las variables futuras (f_promos_planeadas, f_descuento_planeado, f_dias_promo_restantes) y el simulador *What-If* reflejen con fidelidad la estrategia comercial real, Bnext dispone de **dos mecanismos de carga ya construidos** en 1_datos/13_calendario_promociones_plan:

- **Vía 1 · Carga manual ágil mediante Plantilla Excel o CSV (lista hoy sin tocar código):** Reemplazar calendario_promociones_plan.xlsx (hoja promociones)

o su equivalente `.csv` en `/Volumes/modeladoprescriptivoventas/maestria/outputs/calendario/`. En esa misma ruta el notebook genera automáticamente el archivo de consulta **`catalogo_categorias.csv`** con todos los `categoria_id` y `categoria_nombre` válidos del catálogo limpio.

- **Vía 2 · Conexión directa a Tabla Delta, Parquet o CSV corporativo (`MAPEO_COLUMNAS_BNEXT`):** Si Bnext deposita su catálogo maestro de promociones como tabla en Unity Catalog (p. ej. `silver_promociones_bnext`) o archivo automatizado, **no es necesario copiar datos manualmente al Excel**: basta abrir la Sección 2 de `13_calendario_promociones_plan`, descomentar el bloque `CUANDO BNEXT ENTREGUE SU CATÁLOGO DE PROMOCIONES`, indicar la ruta o tabla en `ORIGEN_CATALOGO_BNEXT` y asociar los nombres de columna propios de Bnext en el diccionario `MAPEO_COLUMNAS_BNEXT`. *(Nota: si el catálogo nativo de Bnext viene desglosado por SKU/`producto_id`, debe cruzarse previamente con `silver_catalogo_productos` para consolidarlo al grano `promo_id × categoria_id × alcance`, tomando la mediana o máximo representativo de descuento).*

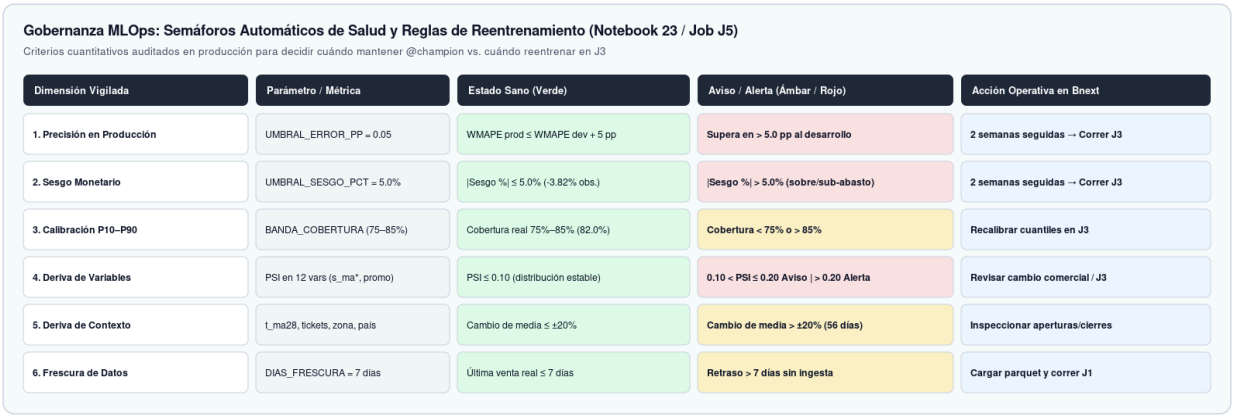
Campo del Contrato	Carácter	Formato y Reglas de Validación en `13_calendario_promociones_plan`
`promo_id`	**Obligatorio**	Identificador de campaña (ej. `BNX-2026-11-BUENFIN`). Se repite en varias filas cuando una promoción aplica a múltiples categorías o regiones.
`inicio_planeado`, **`fin_planeado`**	**Obligatorios**	Fechas de vigencia en formato **`AAAA-MM-DD`**. Deben cumplir `fin >= inicio` y una duración **`<= 120 días`** (rangos mayores se rechazan como error).
`categoria_id` o **`categoria_nombre`**	**Obligatorio**	Clave o nombre exacto existente en `silver_catalogo_categorias` (`catalogo_categorias.csv`). **Comodín temporal:** si aún solo se tienen fechas generales, usar `categoria_id = TODAS` y `tipo_categoria = mercancia` (expande a todas las categorías del tipo, aunque diluye la señal hasta capturar el detalle real).
`descuento_planeado`	**Recomendado**	Profundidad equivalente en fracción `0–1` (`0.15` = 15%; **2x1 = `0.50`**; **3x2 = `0.33`**) o escala `0–100` (`15` se divide entre `100` automáticamente). Si se deja vacío, se imputa la mediana histórica de descuento de esa categoría (`descuento_imputado = 1`).
`tienda`, **`zona`**, **`region`**	**Opcionales (Alcance)**	Dejar **las tres vacías = alcance Nacional** (todas las tiendas activas). Llenar solo el nivel aplicable acota la promoción a ese subconjunto (validado contra `silver_catalogo_tiendas`).
`fecha_publicacion`	**Crítico (Anti-fuga)**	Fecha `AAAA-MM-DD` en que se aprobó/conoció oficialmente el plan. En un corte T solo se activan campañas con `fecha_publicacion <= T`. Si viene vacía, asume `inicio_planeado - 14 días`.
`fuente`, **`tipo_mecanica`**, **`nombre`**, **`comentario`**	**Metadatos**	Capturar siempre **`fuente = bnext`** (si queda vacía se asigna `bnext` por defecto; **retirar todas las filas `placeholder`**). `tipo_mecanica` documenta `descuento`, `lleva 2 paga 1`, `combo`, etc.

Importante — Recomendación de control de calidad al activar el catálogo oficial: Por defecto, el parámetro `FALLAR_SI_INVALIDO` en `13_calendario_promociones_plan` vale `False` (omite filas con categorías o tiendas inexistentes y publica el resto mostrando una tabla de advertencias). Una vez que Bnext conecte su catálogo oficial en producción, se

recomienda fijar **`FALLAR_SI_INVALIDO = True`** en la tarea 13 del Job **`J2 features`** para garantizar que ningún error de captura pase inadvertido.

6. Política de Monitoreo, Gobernanza y ¿Cuándo Reentrenar el Modelo?

Una ventaja central de la arquitectura entregada es que **pronosticar cada semana o cambiar promociones NO requiere reentrenar**. El reentrenamiento (`J3 entrenamiento`) se reserva exclusivamente para incorporar nuevos regímenes estacionales o corregir degradaciones detectadas objetivamente por `23_monitoreo`.



Gobernanza MLOps: Semáforos Automáticos de Salud y Reglas de Reentrenamiento (Notebook 23 / Job J5)

Criterios cuantitativos auditados en producción para decidir cuándo mantener @champion vs. cuándo reentrenar en J3

Dimensión Vigilada	Parámetro / Métrica	Estado Sano (Verde)	Aviso / Alerta (Ámbar / Rojo)	Acción Operativa en Bnext
1. Precisión en Producción	UMBRAL_ERROR_PP = 0.05	WMAPE prod ≤ WMAPE dev + 5 pp	Supera en > 5.0 pp al desarrollo	2 semanas seguidas → Correr J3
2. Sesgo Monetario	UMBRAL_SESGO_PCT = 5.0%	|Sesgo %| ≤ 5.0% (-3.82% obs.)	|Sesgo %| > 5.0% (sobre/sub-abasto)	2 semanas seguidas → Correr J3
3. Calibración P10–P90	BANDA_COBERTURA (75–85%)	Cobertura real 75%–85% (82.0%)	Cobertura < 75% o > 85%	Recalibrar cuantiles en J3
4. Deriva de Variables	PSI en 12 vars (s_ma*, promo)	PSI ≤ 0.10 (distribución estable)	0.10 < PSI ≤ 0.20 Aviso | > 0.20 Alerta	Revisar cambio comercial / J3
5. Deriva de Contexto	t_ma28, tickets, zona, país	Cambio de media ≤ ±20%	Cambio de media > ±20% (56 días)	Inspeccionar aperturas/cierres
6. Frescura de Datos	DIAS_FRESCURA = 7 días	Última venta real ≤ 7 días	Retraso > 7 días sin ingesta	Cargar parquet y correr J1

6.1 Reglas Exactas: ¿Cuándo SÍ y Cuándo NO Reentrenar?

- **Cuándo NO reentrenar:**
  - En la operación semanal ordinaria de los lunes (`J4 Inferencia`).
  - Cuando se edita `calendario_promociones_plan.xlsx` para probar o publicar campañas nuevas (`J2 → J4`).
  - Cuando aparece una alerta aislada de una sola semana provocada por un evento atípico puntual (p. ej. interrupción logística local o día festivo extraordinario).
- **Cuándo SÍ reentrenar (Disparadores Formales):**
  1. **Cadencia preventiva programada (Mensual / Bimestral):** Tras cargar y validar un nuevo cierre mensual completo en la tabla Oro para que los árboles y pesos convexos de `E3 · Blending` absorban la estacionalidad más reciente. *(Nota de estado actual: `J4` ya operó en verde con datos de octubre hasta el `2026-10-31` empleando el modelo auditado al cierre de septiembre; cuando Bnext desee incorporar octubre a los pesos entrenados, este es el primer candidato natural para correr `J3`).*
  2. **Degradación sostenida de precisión (`UMBRAL_ERROR_PP = 0.05`):** Si durante **2 semanas consecutivas** el `WMAPE` de producción supera en **más de**

5.0 puntos porcentuales al benchmark de desarrollo (`0.4447`, es decir, `WMAPE > ~0.495`).

3. **Desviación sostenida de sesgo (`UMBRAL_SESGO_PCT = 5.0%`):** Si durante **2 semanas consecutivas** el sesgo porcentual absoluto rebasa **`±5.0%`**, señalando riesgo sistemático de sobrestock (`> +5%`) o desabasto (`< -5%`).
4. **Descalibración de bandas de seguridad (`BANDA_COBERTURA = 75%–85%`):** Si la cobertura empírica del intervalo conformal `P10–P90` cae por debajo de **`75%`** (bandas demasiado estrechas) o supera **`85%`** de forma persistente (bandas excesivamente anchas).
5. **Deriva estructural de datos (`UMBRAL_PSI_ALERTA = 0.20`):** Si el *Population Stability Index (PSI)* supera **`0.20`** en las variables clave de demanda/promoción (`s_ma7`, `s_ma28`, `s_ma56`, `s_tasa_descuento_28`, `s_intensidad_promo_28`, etc.) respecto a las últimas 8 semanas de entrenamiento (`DIAS_REFERENCIA_DERIVA = 56`). Valores entre `0.10` y `0.20` generan aviso preventivo.

6.2 Procedimiento Seguro para Reentrenar y Promover (`@challenger` → `@champion`)

Para garantizar que ningún reentrenamiento degrade la producción en vivo, el proyecto implementa el patrón **Campeón–Retador (*Champion–Challenger*)** en Unity Catalog:

2. **Prueba rápida de humo (opcional recomendada si se modificó código o catálogo):** Ejecutar `Avance5.43` con `MODO_RAPIDO = True` (~15–25 min) para verificar lectura de tablas y ausencia de errores de entorno.
3. **Corrida formal de `J3 entrenamiento`:** Lanzar **`J3 entrenamiento`** (`MODO_RAPIDO = False`, `REENTRENAR_FINAL = True`; duración estimada `4–6 h`). Al finalizar:
   - Re-optimiza y evalúa la familia de modelos y ensambles, recalibra `Q_Conformal`, verifica la compuerta técnica automática (`technical_pass = True`) y registra la nueva versión en `modeladoprescriptivoventas.maestria.demanda_categoria` bajo el alias **`@challenger`** *(sin alterar `@champion`, por lo que `J4` sigue protegido)*.
2. **Evaluación y promoción gobernada (`3_operacion/24_promocion_modelo`):**
   - Correr `24_promocion_modelo` con `ACCION = evaluar`: compara formalmente `@challenger` contra `@champion` en los bloques no vistos verificando no regresión (`TOLERANCIA_WMAPE`) y audita que existan las aprobaciones registradas en `mlops_aprobaciones`.
   - Si el retador supera la evaluación, correr `24_promocion_modelo` con `ACCION = promover`: mueve el alias **`@champion`** a la nueva versión y archiva trazabilidad completa en MLflow y `mlops_*`.
3. **Actualización inmediata del pronóstico y Rollback en 1 minuto:** Lanzar **`J4 Inferencia`** para refrescar el tablero con el nuevo `@champion`. Si en cualquier

momento se detectara un comportamiento indeseado en negocio, basta reasignar el alias `@champion` a la versión inmediata anterior en Unity Catalog sin reentrenar nada.

7. Restricciones del Entorno Serverless Actual y Guía de Migración a Clúster Dedicado

Todo el desarrollo, validación y puesta en marcha operativa de este proyecto se ejecutó **100% sobre cómputo Azure Databricks Serverless** (tanto en notebooks interactivos como en los cinco Workflows `J1` a `J5` y el SQL Warehouse del tablero). Si bien esta arquitectura permitió entregar una solución funcional sin requerir aprovisionamiento previo de infraestructura dedicada por parte de Bnext, impuso **restricciones técnicas concretas** que el código tuvo que absorber defensivamente. A continuación se documentan dichas restricciones, qué debe hacerse exactamente si Bnext habilita un clúster dedicado y cuáles son las ventajas directas de dar ese paso.



7.1 Restricciones Enfrentadas al Ejecutar Todo en Databricks Serverless

1. **Tope rígido de memoria RAM por contenedor (`cgroup` ~16 GB):**
    a. En cómputo Serverless el proceso de Python corre dentro de un contenedor aislado cuyo límite real en `/sys/fs/cgroup/memory.max` (~16 GB) es muy inferior a la memoria física del servidor anfitrión. Si las matrices de entrenamiento o evaluación en `pandas` / `LightGBM` / `CatBoost` superan dicho umbral, el contenedor se termina abruptamente por falta de memoria (*Out-Of-Memory*).
    b. Para evitar fallos silenciosos, se programó la función `memoria_disponible_gb()` en `Avance5.43`, la cual lee directamente el límite `cgroup`, fija `NIVEL_RAM = 16` y acota `max_filas_entrenamiento = 3,500,000` filas (muestra uniforme reproducible) y `max_filas_bloque = 9,000,000`.
2. **Ejecución sobre *Spark Connect* sin acceso a `SparkContext` ni *workers* de ML:**
    a. Serverless opera exclusivamente mediante el protocolo desacoplado **Spark Connect**: no existe acceso a `spark.sparkContext`, APIs de RDDs, variables

broadcast de objetos pesados de Python hacia ejecutores ni scripts de inicialización de nodo.

   b. En consecuencia, todo el entrenamiento de árboles (`LightGBM`, `XGBoost`, `CatBoost`), la búsqueda bayesiana (`Optuna`) y la re-puntuación de escenarios promocionales corren en **un solo contenedor cliente de CPU** (limitado a los núcleos visibles en `os.sched_getaffinity(0)` y sin aceleración GPU). Esto explica que en `J4 Inferencia` la tarea `30_simulacion_escenarios_whatif` (que re-puntúa 5 escenarios sobre millones de registros) tomara **53m 33s**, `22_pronostico_operativo` **18m 59s**, y que `J3 entrenamiento` requiera **4 a 6 horas** (además de mantener desactivado por defecto `I6_Theta = False` por costo de cómputo).

3. **Entorno efímero en cada corrida y sensibilidad estricta de dependencias (`%pip` / YAML):**
   a. A diferencia de Databricks Runtime ML donde las bibliotecas científicas ya vienen preinstaladas en la imagen base, cada ejecución Serverless arranca un contenedor limpio que debe descargar e instalar `lightgbm`, `xgboost`, `catboost`, `optuna` u `openpyxl` en frío y ejecutar `dbutils.library.restartPython()`, añadiendo minutos de arranque en cada tarea.
   b. Asimismo, el gestor de entornos Serverless traduce las celdas `%pip install` a una especificación YAML estricta en el panel **Environment**: el uso de comillas dobles estándar en especificaciones de versión (p. ej. `"catboost>=1.2,<2"` o `"openpyxl>=3.1,<4"`) provocaba el fallo `ERROR_INVALID_REQUIREMENT` al lanzar Jobs hasta que se depuraron sin comillas y se fijaron explícitamente en el entorno del notebook.
4. **Controles acotados en la interfaz de Workflows y cuotas compartidas:**
   a. En tareas Serverless la interfaz de Jobs no expone el control clásico de *Timeout* duro de clúster a nivel tarea (sustituyéndolo por umbrales de advertencia en *Metric thresholds*, como se observó al configurar `J3 entrenamiento`), ni permite elegir familias de máquinas optimizadas en memoria o instancias *Spot* para abatir costos en cargas largas.
5. **Permisos acotados a un esquema único compartido (`ESQUEMAS_PROPIOS = False`):**
   a. Derivado de los privilegios asignados a la cuenta externa en el workspace, no fue posible ejecutar `CREATE SCHEMA` para separar capas en esquemas independientes (`bronze`, `silver`, `gold`, `mlops`), por lo que la función `tabla(capa, nombre)` se configuró con `ESQUEMAS_PROPIOS = False` para convivir ordenadamente mediante prefijos dentro de `modeladoprescriptivoventas.maestria`.

7.2 ¿Qué Debe Hacer Bnext Paso a Paso si Cuenta con un Clúster Dedicado?

El código entregado por el Equipo 43 fue diseñado con **abstracción completa de infraestructura**: no contiene rutas fijas a Serverless ni requiere reescribir lógica SQL o de modelado para migrar a un clúster. Si Bnext habilita cómputo dedicado, se recomienda usar **Job Clusters efímeros** (que se encienden solo al iniciar el Job y se apagan automáticamente al terminar) siguiendo estos **5 pasos**:

1. **Definir los perfiles de *Job Cluster* con Databricks Runtime LTS ML:**
    a. Seleccionar **`Databricks Runtime 15.4 LTS ML`** (o `16.x LTS ML`), que ya incluye de fábrica `lightgbm`, `xgboost`, `scikit-learn`, `optuna`, `shap` y `mlflow` compilados y optimizados.
    b. **Perfil para `J1 Ingesta_mes` y `J2 features` (intensivos en Spark/Delta):** Driver de `16–32 GB` RAM + auto-escalado de **`2 a 8 workers`** (`Standard_DS4_v2` o `Standard_E4ds_v5` en Azure) habilitando instancias **Spot** en los *workers* (con *fallback on-demand*).
    c. **Perfil para `J3 entrenamiento` y `J4 Inferencia` (intensivos en memoria de Driver y árboles ML):** Driver optimizado en memoria de **`32 GB`** o **`64 GB` RAM** (`Standard_E8ds_v5`, 8 vCPUs / 64 GB RAM; o nodo con GPU T4/A10 si se desea acelerar `CatBoost`/`XGBoost`) + `2 a 4 workers` para las lecturas y agregaciones Delta. *(Si en su lugar se usa un All-Purpose Cluster interactivo, configurar auto-terminación estricta en `15 minutos` de inactividad).*
2. **Declarar las bibliotecas faltantes a nivel Clúster y limpiar `%pip install`:**
    a. En la pestaña **Libraries** de la definición del clúster (PyPI), registrar únicamente **`catboost>=1.2,<2`** y **`openpyxl>=3.1,<4`** (el resto ya vive en DBR ML).
    b. Comentar o retirar las celdas iniciales `%pip install ...` y `dbutils.library.restartPython()` en los notebooks `13`, `Avance5.43`, `22` y `30` para eliminar el tiempo muerto de instalación en cada corrida.
3. **Cambiar el campo `Compute` en las tareas de `J1` a `J5` y fijar *Timeouts* duros:**
    a. En **Jobs & Pipelines**, abrir cada tarea de `J1`, `J2`, `J3`, `J4` y `J5`, cambiar `Compute` de `Serverless` al **`Job Cluster`** correspondiente (reutilizando el mismo *Job Cluster* entre todas las tareas de un mismo Job para que arranque una sola vez por flujo) y configurar **`Timeout`** explícito (`8 h` en `J3`, `2 h` en `J1`/`J4`, `1 h` en `J2`, `30 min` en `J5`).
    b. **Importante:** Mantener el **SQL Warehouse Serverless** exclusivamente para el tablero AI/BI `mna_equipo43_demanda`, ya que en consultas interactivas cortas (`< 1 s`) el SQL Warehouse Serverless sí ofrece arranque instantáneo y óptimo costo-beneficio.
4. **Aprovechar el auto-escalado nativo ya programado en `Avance5.43` (Cero cambios de código obligatorios):**
    a. Al correr sobre un Driver de `32 GB` o `64 GB` RAM, las funciones `memoria_disponible_gb()` y `runtime_threads()` en `Avance5.43` detectarán automáticamente los nuevos recursos (`NIVEL_RAM = 32` o `64`) y

escalarán por sí solas `max_filas_entrenamiento` de `3.5M` a `7.0M` o `14.0M` de filas, además de usar todos los núcleos físicos del nodo.

b. Opcionalmente, en `Avance5.43` se puede cambiar `"I6_Theta": True` para incluir el modelo estadístico por serie en Spark dentro de los ensambles, y en `30_simulacion_escenarios_whatif` se puede envolver la puntuación de los 5 escenarios en un `applyInPandas` distribuido sobre los *workers*.

5. **Opcional — Separar esquemas Medallón reales si un administrador otorga permisos:**
   a. Si el administrador de Unity Catalog crea los esquemas `bronze`, `silver`, `gold` y `mlops` dentro de `modeladoprescriptivoventas`, basta cambiar `ESQUEMAS_PROPIOS = True` en la celda de configuración común para que `tabla(capa, nombre)` enrute todo limpiamente sin modificar ninguna consulta.

7.3 Ventajas Técnicas, Operativas y Económicas de Operar en un Clúster Dedicado

Dimensión	Estado Actual en Serverless	Con Clúster Dedicado / Job Cluster (DBR ML)	Beneficio Directo para Bnext
Volumen de Entrenamiento en RAM (`Avance5.43`)	Tope `cgroup` (~16 GB) limita `max_filas_entrenamiento` a **`3,500,000` filas**.	Auto-escala sin tocar código a **`7,000,000` (32 GB)** o **`14,000,000` filas (64 GB)** (o 100% del histórico).	Mayor precisión estadística en tiendas/categorías de rotación media-baja y cero riesgo de cierres OOM.
Tiempo de Inferencia y What-If (`J4`)	**`~77 min`** totales (`30_whatif` = `53m 33s`, `22_pronostico` = `18m 59s` en CPU pequeña).	Estimado de **`15 a 25 min` totales** (`50%–75%` más rápido con más vCPUs y paralelismo en *workers*).	Permite re-simular cambios de último minuto en promociones varias veces en una misma mañana.
Tiempo de Reentrenamiento (`J3`)	**`4 a 6 horas`** instalando paquetes en frío y entrenando en un solo contenedor CPU.	Estimado de **`1.5 a 2.5 horas`** en Driver de 16–32 vCPUs (y aún menor con GPU en `CatBoost`/`XGBoost`).	Facilita reentrenamientos mensuales ágiles e incorporar más ensayos de `Optuna` o modelos como `I6_Theta`.
Estabilidad de Librerías y Arranque	`%pip install` + `restartPython()` en cada tarea; riesgo ante cambios en la imagen Serverless.	Paquetes preinstalados y congelados en **DBR LTS ML**; cero reinstalación entre tareas del mismo Job.	Eliminación definitiva de fallos de resolución de paquetes (`ERROR_INVALID_REQUIREMENT`) en producción.
Gobernanza y Costo en Cargas Pesadas (DBU)	Tarifa por DBU Serverless más alta en cómputo sostenido de varias horas; sin nodos *Spot*.	Tarifa de **Jobs Compute DBU** sustancialmente menor + hasta `60%–80%` de ahorro en *workers* con **Azure Spot**.	Menor costo mensual de nube en los procesos batch pesados (`J1`, `J3`, `J4`) con *Timeouts* duros garantizados.

8. Límites Declarados, Confidencialidad y Estado de Entrega a Bnext

En apego a las buenas prácticas de ingeniería responsable y transparencia académica, se documentan los alcances y supuestos vigentes al cierre del proyecto:

1. **Confidencialidad estricta de cifras privadas (`MODO_PUBLICO = True`):** Ningún dato transaccional ni monto confidencial del catálogo privado de Bnext se expone en repositorios externos; toda consulta monetaria ocurre exclusivamente dentro del

workspace gobernado de Azure Databricks mediante el tablero AI/BI `mna_equipo43_demanda`.

2. **Calendario promocional en espera del plan comercial definitivo:** El archivo `calendario_promociones_plan.xlsx` incluye actualmente registros demostrativos identificados como `fuente = placeholder`. Las estimaciones de aporte promocional y escenarios What-If adquirirán validez comercial plena en cuanto Bnext sustituya dichas filas por su calendario oficial (`fuente = bnext`).
3. **Pedido neto sujeto a inventario en mano:** El módulo `31_desagregacion_predicciones_sku` prescribe la demanda esperada (`P50`) y el techo de cobertura (`P90`) en unidades por SKU × tienda × semana con reconciliación 100% aditiva; al integrarse en el futuro la tabla de existencias diarias por tienda, el sistema podrá emitir directamente órdenes netas de reabastecimiento.
4. **Sincronización recomendada con repositorio Git:** Durante la puesta en marcha en Serverless se aplicaron ajustes directos en el workspace (limpieza de comillas en `%pip install` de notebooks operativos, compatibilidad ANSI/categóricas y propiedades `"allowHTMLByDefault": false` en las 6 tablas de `mna_equipo43_demanda.lvdash.json`, además del encadenamiento `Run Job` entre `J1 → J2 → J4`). Se recomienda exportar la carpeta `/Workspace/Users/externo1@bnext.mx/mna_equipo43_avance6` actualizada hacia el repositorio Git oficial para preservar paridad 1:1.

Equipo 43 · Maestría en Inteligencia Artificial Aplicada (MNA) · Tecnológico de Monterrey & Bnext / Tiendas SIX · Noviembre de 2026

En apego a las buenas prácticas de ingeniería responsable y transparencia académica, se documentan los alcances y supuestos vigentes al cierre del proyecto:

1. **Confidencialidad estricta de cifras privadas (`MODO_PUBLICO = True`):** Ningún dato transaccional ni monto confidencial del catálogo privado de Bnext se expone en repositorios externos; toda consulta monetaria ocurre exclusivamente dentro del workspace gobernado de Azure Databricks mediante el tablero AI/BI `mna_equipo43_demanda`.
2. **Calendario promocional en espera del plan comercial definitivo:** El archivo `calendario_promociones_plan.xlsx` incluye actualmente registros demostrativos identificados como `fuente = placeholder`. Las estimaciones de aporte promocional y escenarios What-If adquirirán validez comercial plena en cuanto Bnext sustituya dichas filas por su calendario oficial (`fuente = bnext`).
3. **Pedido neto sujeto a inventario en mano:** El módulo `31_desagregacion_predicciones_sku` prescribe la demanda esperada (`P50`) y el techo de cobertura (`P90`) en unidades por SKU × tienda × semana con reconciliación 100% aditiva; al integrarse en el futuro la tabla de existencias diarias por tienda, el sistema podrá emitir directamente órdenes netas de reabastecimiento.

4. **Sincronización recomendada con repositorio Git:** Durante la puesta en marcha en Serverless se aplicaron ajustes directos en el workspace (limpieza de comillas en `%pip install` de notebooks operativos, compatibilidad ANSI/categóricas y propiedades `"allowHTMLByDefault": false` en las 6 tablas de `mna_equipo43_demanda.lvdash.json`, además del encadenamiento `Run Job` entre `J1 → J2 → J4`). Se recomienda exportar la carpeta `/Workspace/Users/externo1@bnext.mx/mna_equipo43_avance6` actualizada hacia el repositorio Git oficial para preservar paridad 1:1.