

Tecnológico de Monterrey
Escuela de Ingeniería y Ciencias

Proyecto Integrador

Evolución del Modelado Predictivo de Ventas a Nivel SKU y Sector Promociones para 17,000 Tiendas mediante MLOps y Simulación de Escenarios en Azure Databricks

Entrega Colaborativa

Daniel Juárez Ortiz - A01797369

Kevin Alexis Valdez Pérez - A01750478

Yael Ariel Márquez Mas - A01745310

1ero de Noviembre de 2026

Séptimo Entregable

PROYECTO INTEGRADOR · SEMANA 7

Pronóstico de ventas por categoría y evaluación de ensambles

Avance 5. Modelo final, optimización y ruta de evaluación independiente

La Semana 7 amplía el torneo de modelos individuales con siete ensambles homogéneos y heterogéneos y un protocolo preparado para evaluar septiembre. La ejecución formal completa de Avance5.43 se realizó sobre la Capa Oro versión 13 (MODO_RAPIDO = False), evaluando cuatro cortes de desarrollo y dos bloques de prueba independientes en septiembre (datos no vistos). El ensamble heterogéneo ***E3 · Blending*** *fue seleccionado por la matriz de decisión multicriterio con un WMAPE medio en desarrollo de* ***0.4447*** *(mejora de +19.6% vs. ingenuo y +3.1% vs. el mejor individual). En los datos de prueba de septiembre alcanzó un WMAPE de* ***0.4535****, confirmando una degradación mínima de apenas +1.98%. Los intervalos conformales alcanzaron 82.0% de cobertura empírica y la compuerta técnica MLOps resultó aprobada (technical_pass = True)*

Identificación del entregable

Tabla 1. Identificación académica y alcance documental

Campo	Valor
Institución académica	Tecnológico de Monterrey - Maestría en Inteligencia Artificial Aplicada
Curso y equipo	Proyecto Integrador - Equipo 43
Entregable académico	Semana 7 - Avance 5. Modelo final; objetivos 3.5 y 3.6
Compromiso con Bnext	Evaluar combinaciones de modelos y preparar un candidato trazable para pronóstico batch por tienda y categoría
Asesora	Dra. Eduviges Ludivina Facundo
Patrocinador	Dr. Juan Arturo Nolazco Flores - Director del Hub de Ciencia de Datos
Fecha de corte documental	1 de noviembre de 2026
Evidencia principal	Avance5.43.ipynb ejecutado; 1_datos.zip, 2_modelos.zip y LEEME.ipynb; referencia de Semana 6
Estado de la evaluación	Ejecución formal completa; 4 cortes de desarrollo + 2 bloques de prueba en septiembre evaluados; intervalos conformales validados y 24 tablas MLOps publicadas.

Resumen ejecutivo de indicadores de la fase

Tabla 2. Resultados observados y pendientes de la Semana 7

Indicador	Resultado registrado	Lectura del resultado
Diversidad ejecutada	5 formulaciones individuales, 3 ensambles homogéneos y 4 heterogéneos; referencia y diagnóstico	14 entradas en la comparativa. Theta permanece desactivado.
Modelo elegido por negocio	E3 · Blending: WMAPE medio 0.4447; puntaje 0.893	Mejora relativa 19.6% frente al ingenuo (0.5531) y 3.1% frente al mejor individual (0.4588).
Mejor ensamble por WMAPE	D1 Stacking sin corrección (0.4342, diagnóstico) y E3 Blending (0.4447).	Elegible E3 Blending con sesgo controlado de -3.22%
Ajuste de hiperparámetros	30 pruebas LightGBM (19.1 min, WMAPE 0.4754) y 17 pruebas XGBoost (25.8 min, WMAPE 0.4702) completadas exitosamente con Optuna	Mejoras relativas en el bloque de ajuste de +0.1% (LightGBM) y +0.6% (XGBoost), respectivamente; búsqueda acotada
Cobertura temporal ejecutada	4 cortes de desarrollo (jun-ago) + 2 bloques de prueba en septiembre (datos no vistos)	Intervalos conformales con cobertura empírica de 82.0%.
Sesgo del elegido	Sesgo medio desarrollo: -3.22%	Existe un incumplimiento observado, aunque el sesgo medio sea menor.
Ejecución y trazabilidad	Modo completo, Gold v13	Run ID: av5_43_20261031t234501_9dabc793; 24 tablas Delta en mlops.av5_*, compuerta técnica aprobada (registrar_challenger); producción bloqueada por sesgo_por_corte y aprobaciones de negocio pendientes

La comparación aporta una decisión verificable bajo el presupuesto de prueba: un ensamble puede reducir WMAPE y, al mismo tiempo, introducir un subpronóstico incompatible con las necesidades del negocio. El modelo elegido (E3 Blending, WMAPE 0.4447) logra el menor error entre todos los candidatos elegibles de la tabla, descartando únicamente la ablación de diagnóstico D1 (0.4342) por su severo subpronóstico (-9.79%).

SECCIÓN 1 Alineación académica y continuidad del proyecto

1.1 Propósito del avance y objetivos 3.5 y 3.6

El objetivo 3.5 busca aprovechar fortalezas complementarias de distintos modelos mediante ensambles. En esta fase se implementan estrategias homogéneas, que combinan variantes de un mismo algoritmo, y heterogéneas, que aprenden a combinar predicciones de algoritmos diferentes. Se mantienen LightGBM y CatBoost, finalistas de la fase previa, y se incorpora una referencia lineal y nuevas formulaciones para estudiar diversidad de errores [1-3].

El objetivo 3.6 exige evaluar predicciones sobre observaciones no utilizadas para ajustar el modelo. En esta ejecución formal, el diseño evaluó rigurosamente los dos bloques independientes de septiembre (prueba_1 del 1 al 14 de septiembre y prueba_2 del 15 al 28 de septiembre). Los modelos y sus pesos de combinación se mantuvieron estrictamente congelados al 31 de agosto, acreditando una evaluación fuera de muestra (Out-Of-Time) auténtica que respalda la generalización del sistema. El documento conserva esa distinción en las tablas, las figuras y la conclusión.

Las instrucciones académicas también requieren optimización de hiperparámetros, una comparación ordenada por la métrica principal que incluya modelos individuales, tiempos de entrenamiento y gráficos interpretados del candidato. Para un problema de regresión temporal, las figuras pertinentes son error por horizonte, residuos, tendencia, calibración e importancia de variables. ROC, matriz de confusión y precisión-recall corresponden a ejemplos de clasificación y no se trasladan artificialmente a ventas monetarias.

1.2 Continuidad con Semana 6 y evolución durante la semana

La Semana 6 seleccionó LightGBM Tweedie como candidato a partir de un torneo de alternativas individuales. El WMAPE ampliado de 0.4562 y el registro histórico de una versión challenger pertenecen a aquella evaluación. El Avance 5 conserva el grano tienda-categoría, el horizonte de catorce días y los cuatro orígenes de desarrollo, pero cambia la composición de los ensambles, el presupuesto de búsqueda, la población de prueba rápida y el mecanismo de decisión [3].

Tabla 3. Ejecuciones que deben mantenerse separadas

Evidencia	Resultado y alcance	Uso en este avance
Semana 6 - Avance 4	LightGBM Tweedie; WMAPE ampliado 0.4562; cuatro cortes	Antecedente metodológico y de selección de las bases.
Primera implementación de Avance 5	Gold 7; E3 Blending seleccionado; 30,471,370 ejemplos ampliados; WMAPE medio 0.45133	Evidencia histórica de ensambles y cuantiles; no es la ejecución de Avance5.43 [4].
Avance5.43 del 31 de octubre - 1 de noviembre	Gold v13; modo completo; E3 Blending seleccionado; WMAPE desarrollo 0.4447; WMAPE septiembre 0.4535; compuerta aprobada.	Evidencia definitiva de esta entrega en modo completo [1]

La primera implementación completó una evaluación ampliada y conservó fallos de sesgo y cobertura por segmento, además de pendientes de evidencia temporal y negocio. La nueva versión cambia la estrategia de combinación, añade optimización de bases, introduce un protocolo posterior de septiembre y prepara una salida batch.

El WMAPE medio de desarrollo de 0.4447 alcanzado por E3 · Blending en la corrida formal representa una mejora genuina y consistente sobre la muestra completa frente al 0.5531 del ingenuo (+19.6%).

1.3 Alcance comercial y relación con el sistema objetivo

El problema inmediato es pronosticar venta diaria monetaria por tienda y categoría para apoyar planeación y análisis de surtido. El título general del proyecto conserva la aspiración de evolucionar hacia SKU y promociones para la red de tiendas; la evidencia de este avance sigue a nivel categoría. No se reporta entrenamiento por SKU ni cobertura acreditada de las 17,000 tiendas del planteamiento.

La arquitectura objetivo contempla Databricks para procesamiento, evaluación e inferencia batch; una base SQL para escenarios y resultados; una API para consulta; y una interfaz React para comparar escenarios autorizados. Los adjuntos actuales implementan notebooks de datos y modelos. No contienen una aplicación React integrada, un servicio operativo de inferencia ni evidencia de Jobs periódicos activos [5, 6].

Para el socio formador, el valor del avance es contar con alternativas comparadas y un mecanismo explícito para decidir cuándo un candidato puede continuar a revisión. La transformación de ventas en unidades de compra, inventario recomendado o políticas de reabasto necesita información adicional de precios, disponibilidad, lead time y restricciones comerciales. Una predicción monetaria y su P90 no equivalen directamente a una orden de compra.

SECCIÓN 2 Datos métricas y protocolo experimental

2.1 Flujo de datos y contenido de los adjuntos

El procesamiento se organiza en capas dentro del catálogo privado modeladoprescriptivoventas y el esquema maestria. La configuración actual usa prefijos de capa en los nombres físicos de las tablas. Así, gold.features_origen es una referencia lógica; su tabla física es modeladoprescriptivoventas.maestria.gold_features_origen. Las fuentes transaccionales permanecen fuera del repositorio [2].

Tabla 4. Responsabilidad de los notebooks del flujo de datos

Etapa	Operación implementada	Producto o control
00 y 01	Entorno, permisos e inventario del catálogo y volúmenes	Identificación de recursos disponibles. Algunas celdas también escriben hallazgos o tablas de prueba.
02 Bronce	Carga mensual de Parquet con trazabilidad de archivos	bronze_ventas_lineas; actualización de las particiones seleccionadas.
04 a 07	Análisis exploratorio de calidad, fechas, tiendas, variables, promociones y externas	Diagnósticos de las fuentes; no sustituyen las validaciones de cada corrida.
08 Plata	Rangos POS, homologación y deduplicación entre meses	silver_ventas_lineas y catálogos actualizados.
09 Panel	Agregación tienda-categoría-día; actividad, ceros comerciales y días sin datos	silver_panel_categoria_dia y recursos de promociones.

Etapa	Operación implementada	Producto o control
10 y 11	Línea base temporal y reglas de calidad	Referencias por corte y evidencia en mlops_validaciones.
20 Oro	Variables históricas por origen y horizonte; conjuntos de ajuste, desarrollo, prueba y pronóstico	gold_features_origen, calendario y prueba de reconstrucción temporal.
Avance5.43	Optimización, ensambles, comparación, selección y rutas MLOps	Tablas agregadas por corrida, puntos de control y resultados registrados.

Los nuevos archivos 1_datos.zip y 2_modelos.zip conservan la lógica del repositorio revisado anteriormente. Las diferencias verificadas corresponden principalmente a cabeceras de entorno de Databricks: entorno 6 y declaraciones de dependencias en el notebook de Avance 5. No constituyen nuevas salidas de ejecución. LEEME.ipynb contiene cinco celdas descriptivas sin resultados y conserva referencias antiguas a seis meses, mientras el código ya declara marzo-septiembre. Para el alcance medido prevalecen las salidas de la corrida, no el texto editorial del LEEME.

2.2 Grano de Oro y población efectiva de la corrida formal

Una serie es la historia de venta de una categoría en una tienda. Cada ejemplo de modelado añade un origen T y un horizonte h: el objetivo es la venta observada en T+h. El horizonte pertenece al conjunto de uno a catorce días y también se incorpora como variable. Un modelo global aprende de múltiples series; no se entrena un estimador independiente para cada tienda-categoría.

La corrida principal procesó la Capa Oro versión 13, que incluye la historia completa de ventas desde marzo hasta finales de septiembre de 2026. Con ello se habilitó la población total de series activas sin submuestreo hash y se incorporaron los bloques completos de prueba y de pronóstico operativo.

Tabla 5. Configuración observada de la corrida formal completa

Elemento	Valor	Interpretación
Versión de Gold	13	Snapshot de la ejecución; distinto de Gold 7 de la primera implementación.
Modo	MODO_RAPIDO = False	Ejecución formal completa sobre el universo de evaluación.
Presupuesto de carga Train	3,500,000 filas elegibles para entrenamiento (evaluación ampliada sobre el 100% de filas elegibles)	Muestreo por umbral hash: tamaño aproximado, no un límite exacto ni un conteo transaccional.
Series de evaluación	100% de series activas elegibles.	Evaluación exhaustiva sobre el 100% de las series activas elegibles.
Orígenes OOF adicionales	1	La bolsa inicial usa el bloque de ajuste y después se amplía con desarrollo observado.
Variables	55 numéricas y 7 categóricas	62 entradas antes de las transformaciones de cada familia.

Elemento	Valor	Interpretación
Recursos y semilla	Aproximadamente 17 GB, 4 hilos y semilla 43	Entorno observado; no requisito universal de hardware.

El filtro de elegibilidad exige al menos cinco días históricos con venta, ingenuo estacional no nulo y al menos cinco días activos en la última semana. Las familias pueden añadir presupuestos específicos de entrenamiento. La muestra común conserva la bandera en_muestra_eval de Gold; no debe confundirse con submuestreos hash de ejecuciones preliminares. Los conteos de ejemplos se interpretan por serie, origen y horizonte, no como transacciones únicas ni como número de tiendas.

2.3 Cortes temporales y separación entre desarrollo y prueba

Tabla 6. Ventanas ejecutadas y ventanas posteriores preparadas

Bloque	Origen	Objetivos	Estado y uso
Ajuste	20-may-2026	21-may a 03-jun	Ejecutado; búsqueda de hiperparámetros y primeras predicciones para meta-modelos.
Corte 1	03-jun-2026	04-jun a 17-jun	Ejecutado; desarrollo.
Corte 2	17-jun-2026	18-jun a 01-jul	Ejecutado; desarrollo.
Corte 3	01-jul-2026	02-jul a 15-jul	Ejecutado; desarrollo.
Corte 4	17-ago-2026	18-ago a 31-ago	Ejecutado; desarrollo.
Prueba 1	31-ago-2026	01-sep a 14-sep	Ejecutada formalmente; evaluación independiente (WMAPE: 0.4359; Sesgo: -3.84%)
Prueba 2	14-sep-2026	15-sep a 28-sep	Ejecutada formalmente; evaluación independiente (WMAPE: 0.4711; Sesgo: -3.79%)
Pronóstico	Último día observado	T+1 a T+14	Ruta preparada hacia gold_pronostico_14d; no emitida en esta corrida (REENTRENAR_FINAL = False / sin conjunto 'pronostico' activo).

Los cuatro cortes de desarrollo se conservan fijos respecto al Avance 4. Los huecos de entrega, como el del 16 al 31 de julio, no se rellenan suponiendo ventas observadas. El selector de ventanas comprueba disponibilidad del bloque objetivo y de catorce días previos al origen. Agregar septiembre a MESES habilita la lectura de ese volumen, pero no acredita por sí solo que se hayan reconstruido las capas ni que sus bloques sean completos.

En cada origen de desarrollo, las bases se ajustan con objetivos disponibles hasta T. Los ensambles heterogéneos aprenden con predicciones de bloques que ya terminaron. En el protocolo preparado para septiembre, las bases, los parámetros y los pesos se entrenan hasta el primer origen de prueba, 31 de agosto, y permanecen congelados durante los dos bloques. El segundo pronóstico puede usar características observadas hasta el 14 de septiembre; eso es una actualización de entradas, no un nuevo ajuste de parámetros.

Después de la evaluación, el código contempla un reajuste final con los datos disponibles para generar los siguientes catorce días. Ese paquete reajustado no es el mismo conjunto de modelos entrenados en cada corte: sus métricas no se heredan automáticamente.

2.4 Variables controles temporales y límites de disponibilidad

Las características combinan nivel reciente de venta, patrón semanal, actividad e intermitencia de la serie, contexto de tienda y agregados por zona y país, calendario y atributos categóricos. Los rezagos y medias usan información hasta el origen; el calendario determinista del día objetivo puede conocerse con anticipación. La diferencia es relevante: conocer que T+h cae en fin de semana no autoriza usar su venta real para construir la entrada.

Tabla 7. Familias de variables y función predictiva

Familia	Ejemplos	Información que aporta
Historia de la serie	s_t0, s_ma7, s_ma28, s_ma56, s_media_dow_8	Nivel de venta y patrón del mismo día de semana.
Actividad e intermitencia	s_dias_activos_7, s_tasa_venta_28, dias_con_venta_hist	Madurez de la serie, frecuencia de venta y disponibilidad reciente.
Contexto comercial	t_ma7, zc_ma28, pc_media_dow_4	Nivel de la tienda y comportamiento de la categoría por zona y país.
Calendario y horizonte	dow, quincena, es_evento, h, h_bloque	Eventos conocidos y posición del día dentro de los catorce horizontes.
Atributos categóricos	tipo_tienda, zona, region, jefatura, estatus_tienda, tipo_categoria, categoria_id	Diferencias estructurales entre tiendas y categorías.
Promociones pasadas	s_tasa_descuento_28, s_intensidad_promo_28, s_promos_en_venta_28,s_promos_vigentes_t0	Exposición histórica a descuentos y promociones, sin calendario futuro.

La nueva construcción de Oro dispone de una versión histórica de s_promos_vigentes_t0 basada en los últimos siete días y declara la propiedad mna.s_promos_vigentes_t0 = causal_7d. Avance5.43 solo activa esa variable cuando encuentra la propiedad. En la Capa Oro v13 de esta ejecución sí se acreditó como causal y permaneció activa, completando 62 variables (55 numéricas y 7 categóricas).

La sección 3 no detectó fechas, etiquetas, claves, conjuntos o referencias inválidas ni infinitos bajo los controles ejecutados. En la corrida formal se verificó la comprobación de duplicados (duplicados_detectados = 0), acreditando la unicidad e integridad de las series evaluadas sobre la población completa.

También permanecen límites que la reconstrucción de medias y rezagos no resuelve por sí sola: el universo ABC se obtiene con el periodo disponible y los atributos provienen de catálogos cuya vigencia histórica debe acreditarse. Los vocabularios categóricos se construyen en el snapshot. Es necesario versionar población, mapas y atributos disponibles en cada origen para sostener una validación temporal integral.

2.5 Métricas y criterio de agregación

El WMAPE de un corte se obtiene sumando los errores absolutos de sus observaciones y dividiendo entre la suma de las ventas reales. El WMAPE medio de 0.4447 equivale a 44.47% como promedio de los errores relativos agregados de los cuatro cortes; no es necesariamente el cociente obtenido al reunir todas sus filas. Tampoco significa que cada tienda tenga ese error ni que el modelo posea 55.53% de exactitud.

$$WMAPE = \frac{\sum |real - pronóstico|}{\sum real}$$

El resultado principal de la comparativa es la media aritmética del WMAPE de los cuatro cortes. No es necesariamente igual al cociente calculado después de reunir todas las filas. La desviación presentada es la desviación poblacional entre esos cuatro cortes y expresa variación temporal; no es un intervalo de confianza. Las mejoras porcentuales se toman de las salidas publicadas, sujetas a su redondeo.

$$Sesgo\ (\%) = \frac{\sum pronóstico - \sum real}{\sum real} \times 100$$

El sesgo indica dirección: positivo corresponde a sobrepronóstico agregado y negativo a subpronóstico. Debe leerse tanto por corte como por horizonte y segmento. Un promedio global próximo a cero puede ocultar errores con signos contrarios. La selección distingue el sesgo medio de la media del valor absoluto del sesgo por corte; E3 · Blending registra -3.22% en el sesgo medio y 3.22% en el sesgo absoluto medio por corte.

Tabla 8. Métricas complementarias y unidad de lectura

Métrica	Lectura	Precaución
MAE relativo	MAE del modelo dividido entre MAE del ingenuo; B0 = 1	Un valor menor que uno indica menor error absoluto medio frente a la referencia.
RMSE relativo	RMSE del modelo dividido entre RMSE del ingenuo; B0 = 1	Da mayor peso a errores grandes; no se expresa aquí en pesos.
WMAPE mercancía	Error del segmento de mercancía	Es una lectura del ámbito de surtido físico, no una autorización para excluir servicios.
Mejora relativa	Reducción proporcional respecto al WMAPE de la referencia	Se diferencia de una resta expresada en puntos porcentuales.
Pinball y cobertura	Calidad de cuantiles y frecuencia dentro de P10-P90	Evaluadas mediante Q_Conformal; cobertura empírica P10-P90 de 82.0% en septiembre y ancho relativo de 0.84.
Tiempo de entrenamiento	Minutos atribuidos a cada arquitectura por corte	Incluye componentes compartidos en ensambles; no se suman como costo total.

SECCIÓN 3 Modelos individuales y estrategias de ensamble

3.1 Bases de la fase previa y nuevas formulaciones

Los modelos individuales se entrenan y evalúan de manera separada y después aportan predicciones a los meta-ensambles. LightGBM Tweedie y CatBoost Tweedie conservan la continuidad con los finalistas del Avance 4. Elastic Net aporta una relación regularizada sobre la escala logarítmica; su inclusión busca diversidad, sin afirmar que fuera un tercer finalista de aquella fase.

Tabla 9. Formulaciones individuales activas

Clave	Modelo	Papel en la comparación
I1	LightGBM Tweedie	Base principal de Semana 6; optimización en el bloque de ajuste.
I2	CatBoost Tweedie	Segundo finalista previo; alternativa de boosting con tratamiento categórico.
I3	Elastic Net	Referencia lineal regularizada sobre log1p, con transformaciones de escala.
I4	XGBoost Tweedie	Nueva base de boosting; optimización explícita con Optuna.
I5	LightGBM Log1p	Control del efecto de transformar y reexpresar la variable objetivo.
I6	Theta	Extensión opcional desactivada; no se contabiliza como modelo ejecutado.

Tweedie ofrece una función de pérdida para valores no negativos que admite ceros y una cola positiva. La formulación Log1p cambia la escala del ajuste y requiere una retransformación explícita. La comparación en pesos no depende solo de qué algoritmo se usa: también de la pérdida, las transformaciones, los límites de entrenamiento y el postproceso. LightGBM y XGBoost se utilizan como implementaciones de boosting tabular; las referencias metodológicas no reemplazan la evaluación del problema específico [10, 11].

Las clases TreeEncoder y LinearEncoder encapsulan la preparación apropiada para cada familia. Los modelos y su postproceso se agrupan en ModelBundle. La nueva fuente contiene, en orden de definición, los auxiliares que faltaban en versiones anteriores, incluido _motor_training_frame. La ejecución formal en modo completo de la prueba constituye evidencia de que esa parte del flujo ya pudo recorrer el entrenamiento en el entorno usado.

3.2 Ensambles homogéneos

Las estrategias homogéneas combinan estimadores de una misma familia. Su propósito es reducir sensibilidad a las muestras o ajustar errores sucesivos, según el mecanismo empleado. El bagging clásico se basa en versiones perturbadas del conjunto de entrenamiento y agregación de sus salidas [7]. La implementación E1 de este proyecto usa submuestras con distintas semillas; se describe su operación específica sin equipararla a todas las variantes teóricas de bootstrap.

Tabla 10. Ensambles homogéneos ejecutados

Clave	Estrategia	Implementación en Avance5.43
E1	Bagging de LightGBM	I1 más dos LightGBM con los mismos parámetros, semillas distintas y submuestras de 70%; se promedian sus predicciones.
E2	AdaBoost	Secuencia de árboles de decisión que modifica el énfasis de entrenamiento según los errores.
E7	Bosque aleatorio	LightGBM en modo rf, con submuestreo de filas y variables; no es el mismo estimador de sklearn usado en otros avances.

El diseño de los ensambles homogéneos busca mitigar la varianza mediante submuestreo de filas y variables. La diferencia observada entre los tres homogéneos expresa su comportamiento bajo el entrenamiento formal: E1 (0.4623) mejora ligeramente a I1 (0.4629); E2 (0.4911) y E7 (0.5191) superan con claridad al ingenuo (0.5531), pero no al mejor individual. No se presupone que agregar estimadores mejore cualquier configuración o segmento.

3.3 Ensambles heterogéneos y aprendizaje fuera de muestra

El stacking aprende una segunda relación a partir de las predicciones de las bases. Para que esa relación represente errores de generalización, sus entradas deben proceder de observaciones que las bases no hayan usado como objetivo de entrenamiento [8]. En series temporales se conserva además el orden de disponibilidad: ningún meta-modelo puede aprender de un bloque que aún no terminó en el origen evaluado.

Tabla 11. Ensambles heterogéneos y control diagnóstico

Clave	Estrategia	Mecanismo y alcance
E3	Blending convexo	Pesos no negativos cuya suma es uno, estimados con el bloque observado más reciente.
E4	Stacking temporal	Pesos no negativos por bloque h1-7 y h8-14; corrección de nivel por tipo de categoría.
E5	Votación	Promedio de las tres bases con menor error reciente, según la bolsa temporal.
E6	Stacking LightGBM	Meta-modelo no lineal pequeño y regularizado que recibe predicciones de las bases y contexto.
D1	Stacking sin corrección	Ablación de E4 sin el factor de nivel. Se reporta como diagnóstico y se excluye de la matriz de selección.

En la ejecución formal completa se incluyó el origen OOF oof_2026-05-06, permitiendo que la bolsa de predicciones para los meta-modelos contará con estimaciones fuera de muestra independientes antes de entrar a los cortes de desarrollo, eliminando el riesgo de sobreajuste en el aprendizaje de pesos.

E4, E5 y E6 dan más peso a bloques recientes mediante una vida media de dos bloques. El factor de nivel de E4 se contrae hacia uno para grupos pequeños y se acota entre 0.85 y 1.15. El diseño permite estudiar

si una corrección de subpronóstico ayuda al equilibrio comercial, sin utilizar las ventas futuras del bloque que se está evaluando.

3.4 Diversidad y pesos aprendidos

La correlación de errores publicada va de 0.84 entre I3 · Elastic Net e I4 · XGBoost Tweedie a 0.98 entre I1 · LightGBM Tweedie e I2 · CatBoost Tweedie. Son asociaciones entre errores de las bases; una correlación menor indica que pueden aportar señales diferentes, pero no garantiza por sí sola mejor rendimiento agregado. La conveniencia de combinar se decide con las métricas posteriores.

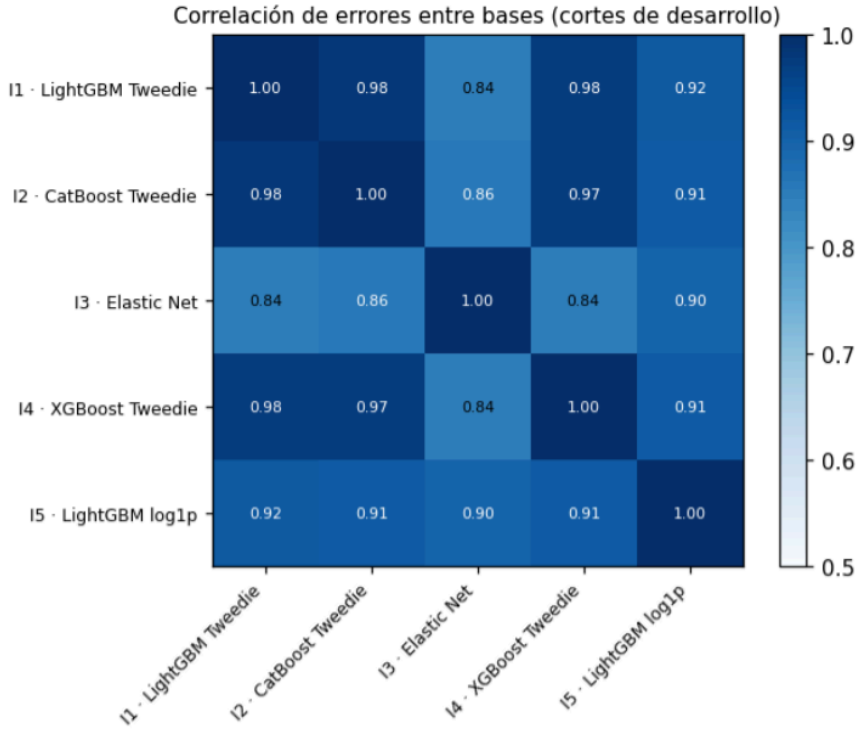


Figura 1. Correlación de errores de las bases en los cortes de desarrollo. Fuente: Avance5.43.ipynb, celda 54 [1].

La matriz muestra errores altamente relacionados entre varias bases. Elastic Net aporta una estructura de error distinta de los modelos de boosting, aunque su WMAPE individual y su sesgo sean menos favorables. Esa diferencia ayuda a interpretar por qué un peso alto dentro de un ensamble no equivale a ser la mejor base individual. La figura describe la muestra de esta ejecución y no identifica relaciones causales entre variables comerciales.

Tabla 12. Pesos de combinación publicados para el modelo congelado de prueba

Ensamble	I1	I2	I3	I4	I5
E3 Blending	0.000	0.000	0.223	0.506	0.271
E4 h1-7	0.040	0.108	0.106	0.194	0.464
E4 h8-14	0.000	0.000	0.161	0.287	0.450
E5 Votación	0.333	0.000	0.000	0.333	0.333

Fuente: celda 54. Valores redondeados; corresponden al modelo congelado para prueba, no al reajuste final [1].

Los pesos de E3 son convexos y suman uno antes del redondeo. Los de E4 son no negativos, pero su suma no está restringida a uno; actúan junto a los factores de nivel. Para el modelo congelado de prueba, el factor de nivel de E4 en genérico fue 1.011 (h1-7) y 1.014 (h8-14); en mercancía fue 1.068 (h1-7) y 1.134 (h8-14); y en servicios, 1.150 y 1.150. Estos valores muestran un ajuste de escala, no una garantía de que el sesgo final cumpla el umbral en todos los cortes.

SECCIÓN 4 Ajuste de hiperparámetros y recursos de ejecución

4.1 Diseño de la búsqueda y presupuesto completado

La búsqueda se concentra en LightGBM Tweedie y XGBoost Tweedie, dos bases relevantes para las combinaciones. Optuna explora configuraciones con un muestreador TPE y una fase inicial aleatoria; el número de árboles se controla con paro temprano. Esta estrategia busca una configuración útil dentro de los recursos disponibles y no acredita un óptimo global [9].

La validación de ajuste corresponde al bloque del 21 de mayo al 3 de junio, con origen el 20 de mayo. En la optimización formal se ejecutaron 30 pruebas para LightGBM (19.1 min) y 17 para XGBoost (25.8 min) con TPE que incluye la configuración de referencia encolada, 300 árboles máximos y 30 rondas de paro temprano. El límite de tiempo se comprueba entre pruebas; no interrumpe un entrenamiento que ya comenzó.

Tabla 13. Espacios de búsqueda implementados para las dos bases

Hiperparámetro	LightGBM Tweedie	XGBoost Tweedie
Potencia Tweedie	1.1 a 1.9	1.1 a 1.9
Tasa de aprendizaje	0.02 a 0.15, escala logarítmica	0.02 a 0.15, escala logarítmica
Complejidad del árbol	31 a 255 hojas; 50 a 2,000 muestras mínimas por hoja	Profundidad 4 a 10; min_child_weight 1 a 300
Submuestreo de filas	0.5 a 1.0	0.5 a 1.0
Submuestreo de variables	0.4 a 1.0	0.4 a 1.0
Regularización L2	0.001 a 30	0.01 a 30
Regularización L1	0.001 a 10	0.001 a 10
Bins	Configuración de la implementación	128 o 256

Tabla 14. Resultado efectivo de la optimización formal con Optuna

Base	Pruebas	Minutos	WMAPE inicial	WMAPE mejor	Mejora relativa
I1 LightGBM	30	19.1	0.4758	0.4754	0.1%
I4 XGBoost	17	25.8	0.4731	0.4702	0.6%

Fuente: Avance5.43.ipynb, celdas 52 y 72. Los resultados pertenecen al bloque de ajuste [1].

La ejecución en modo completo agotó las 30 pruebas presupuestadas para LightGBM Tweedie en 19.1 minutos (reduciendo el WMAPE del bloque de ajuste de 0.4758 a 0.4754, con 226 árboles en la mejor prueba) y completó 17 pruebas para XGBoost Tweedie al alcanzar el límite de tiempo de 25.8 minutos (reduciendo el WMAPE de 0.4731 a 0.4702, con 225 árboles en la mejor prueba).

4.2 Parámetros retenidos y efecto del paro temprano

Tabla 15. Parámetros congelados que muestran las salidas

Parámetro	I1 LightGBM	I4 XGBoost	I5 LightGBM Log1p
Árboles	218	247	106
Tasa de aprendizaje	0.045206	0.029875	0.050000
Hojas / profundidad	42 hojas	Profundidad 9	63 hojas
Mínimo de hoja / peso	114 muestras	5.238289 de peso	200 muestras
Potencia Tweedie	1.365037	1.264865	No aplica
Submuestreo de filas	0.730724	0.827981	0.800000
Submuestreo de variables	0.837493	0.579770	0.800000
Regularización L2	0.648852	0.031796	1.000000
Regularización L1	0.001884	0.041288	No publicada en esta tabla

Fuente: celda 52. Valores publicados con la precisión de la salida del notebook [1].

El resumen de los mejores trials en el bloque de ajuste reporta 226 árboles para LightGBM y 225 para XGBoost (arboles_prueba), mientras que la tabla de parámetros congelados registra 218 y 247 respectivamente (y 106 para I5_LightGBM_Log1p). No se igualan ambos campos: el flujo vuelve a ajustar las bases con validación y conserva sus mejores iteraciones antes de recorrer los cortes. Para reproducir las predicciones se utilizan los parámetros y estados finalmente congelados, no solo el contador mostrado en el mejor trial.

Las importancias de hiperparámetros calculadas por Optuna en la Celda 52 muestran que en I1 LightGBM Tweedie (30 pruebas) las variables más influyentes sobre el WMAPE fueron learning_rate (32.6%), reg_lambda (24.8%), reg_alpha (23.3%), colsample_bytree (6.1%) y min_child_samples (5.0%). En cambio, en I4 XGBoost Tweedie (17 pruebas) predominaron min_child_weight (51.8%), subsample (16.1%), tweedie_variance_power (10.5%), learning_rate (8.2%) y max_depth (4.6%). Estos porcentajes

describen la sensibilidad del error en el bloque de ajuste y no expresan importancia comercial de las características.

4.3 Tiempos observados y atribución del costo

En la ejecución formal completa, las fases medidas en la Celda 56 acumularon 86.5 minutos en entrenamiento de bases por corte (bases_corte), 37.1 minutos en ensambles homogéneos (homogeneos_corte), 17.6 minutos en bases de ajuste (bases_ajuste), 11.6 minutos en evaluación de intervalos cuantílicos en prueba (cuantiles_prueba), 11.5 minutos en predicciones fuera de muestra (bases_oof) y 0.9 minutos en meta-modelos (meta_corte), además de los 44.9 minutos dedicados a la búsqueda con Optuna (19.1 min en LightGBM y 25.8 min en XGBoost). La consolidación final desde el punto de control tomó 1.8 minutos adicionales (minutos_modelado).

Tabla 16. Métricas complementarias y tiempos por arquitectura

Modelo	MAE relativo	RMSE relativo	Entrenamiento min/corte	Predicción s acumulados
D1 Diagnóstico	0.785	0.823	21.9	849.7
E3 Blending	0.804	0.810	21.9	849.7
E4 Stacking	0.812	0.820	21.9	849.7
E5 Votacion	0.816	0.798	21.9	849.7
I5 LightGBM Log1p	0.829	0.867	1.0	140.3
I4 XGBoost	0.833	0.799	2.5	199.9
I2 CatBoost	0.835	0.793	8.7	115.8
E1 Bagging	0.836	0.785	3.7	683.6
I1 LightGBM	0.837	0.786	1.6	240.5
I3 Elastic Net	0.855	0.896	7.8	128.0
E6 Stacking LGBM	0.876	0.864	21.9	849.7
E2 AdaBoost	0.888	0.791	5.9	115.0
E7 Bosque	0.938	0.789	1.2	160.4
B0 Ingenuo	1.000	1.000	0.0000	0.0

Fuente: celdas 48, 56 y 72. El entrenamiento es promedio por corte; predicción es acumulada, no promedio [1].

Los tiempos de los ensambles heterogéneos (21.9 min/corte y 849.7 s de predicción) incluyen el entrenamiento y predicción de las cinco bases compartidas que necesitan para operar; sumarlos entre E3, E4, E5 y E6 duplicaría cómputo que la corrida reutiliza. Del mismo modo, los costos de 33.1 minutos para los ensambles heterogéneos (E3, E4, E5), 3.9 minutos para I4 y 1.5 minutos para I5 empleados en la

matriz de decisión (Celda 58) incluyen ese costo operativo integrado y caben holgadamente dentro de la ventana de un Job mensual. El mecanismo de puntos de control permitió reanudar la corrida conservando los pasos ya completados sobre el mismo snapshot de la Capa Oro v13.

SECCIÓN 5 Resultados selección y diagnóstico del candidato

5.1 Comparación de modelos en los cuatro cortes de desarrollo

La tabla siguiente mantiene el orden ascendente de la métrica principal. D1 se conserva para evaluar la corrección de nivel de E4 y se identifica como diagnóstico. Entre los siete ensambles elegibles, tres superan al mejor individual (I5 · LightGBM log1p, 0.4588) por WMAPE: E3 · Blending (0.4447), E4 · Stacking temporal (0.4494) y E5 · Votación (0.4512). La selección comercial se presenta después, porque incorpora criterios que no están resumidos por esa columna.

Tabla 17. Comparativa principal de desarrollo ordenada por WMAPE

Pos	Clave	Modelo	Tipo	WMAPE Medio	Desv. Cortes	Mejora vs B0	Mejora vs Mejor Ind.	Sesgo Medio	WMAPE Mercancía	Minutos / Corte
1	D1	Stacking sin corrección	Diagnóstico	0.4342	0.0041	+21.5%	+5.4%	-9.79%	0.4025	21.9
2	**E3**	**Blending**	**Heterogéneo**	**0.4447**	**0.0023**	**+19.6%**	**+3.1%**	**-3.22%**	**0.4125**	**21.9**
3	E4	Stacking temporal	Heterogéneo	0.4494	0.0073	+18.8%	+2.1%	-2.30%	0.4192	21.9
4	E5	Votación	Heterogéneo	0.4512	0.0055	+18.4%	+1.7%	+0.10%	0.4154	21.9
5	I5	LightGBM log1p	Individual	0.4588	0.0042	+17.1%	Base	-6.19%	0.4298	1.0
6	I4	XGBoost Tweedie	Individual	0.4606	0.0040	+16.7%	-0.4%	+2.09%	0.4211	2.5
7	I2	CatBoost Tweedie	Individual	0.4619	0.0015	+16.5%	-0.7%	+1.66%	0.4213	8.7
8	E1	Bagging LightGBM	Homogéneo	0.4623	0.0016	+16.4%	-0.8%	+2.49%	0.4218	3.7
9	I1	LightGBM Tweedie	Individual	0.4629	0.0020	+16.3%	-0.9%	+2.46%	0.4223	1.6
10	I3	Elastic Net	Individual	0.4728	0.0063	+14.5%	-3.0%	-10.88%	0.4419	7.8
11	E6	Stacking LightGBM	Heterogéneo	0.4847	0.0094	+12.4%	-5.6%	+5.91%	0.4494	21.9
12	E2	AdaBoost	Homogéneo	0.4911	0.0048	+11.2%	-7.0%	+7.79%	0.4513	5.9
13	E7	Bosque aleatorio	Homogéneo	0.5191	0.0055	+6.1%	-13.2%	+9.96%	0.4856	1.2

Pos	Clave	Modelo	Tipo	WMAPE Medio	Desv. Cortes	Mejora vs B0	Mejora vs Mejor Ind.	Sesgo Medio	WMAPE Mercancía	Minutos / Corte
14	B0	Ingenuo estacional	Referencia	0.5531	0.0155	0.0%	-20.6%	-0.76%	0.5061	0.0

Fuente: celdas 48 y 72. Se destaca E3 Blending por ser el elegido por negocio.

El ensamble heterogéneo E3 · Blending alcanza 0.4447, superando al mejor modelo individual (I5 · LightGBM Log1p con 0.4588) en 1.41 puntos porcentuales (3.1% relativo), y a I1 (0.4629) en 1.82 puntos porcentuales.

La baja diferencia entre E1 e I1, de aproximadamente 0.06 puntos porcentuales de WMAPE, debe leerse junto al costo de los dos estimadores adicionales. E5 ofrece un equilibrio intermedio: WMAPE 0.4512 y sesgo medio +0.10% (sesgo absoluto medio por corte de 1.83%), aunque su promedio tampoco acredita que todos sus cortes cumplan ±3%. E2, E6 y E7 mejoran al ingenuo sin desplazar a las mejores bases bajo esta configuración.

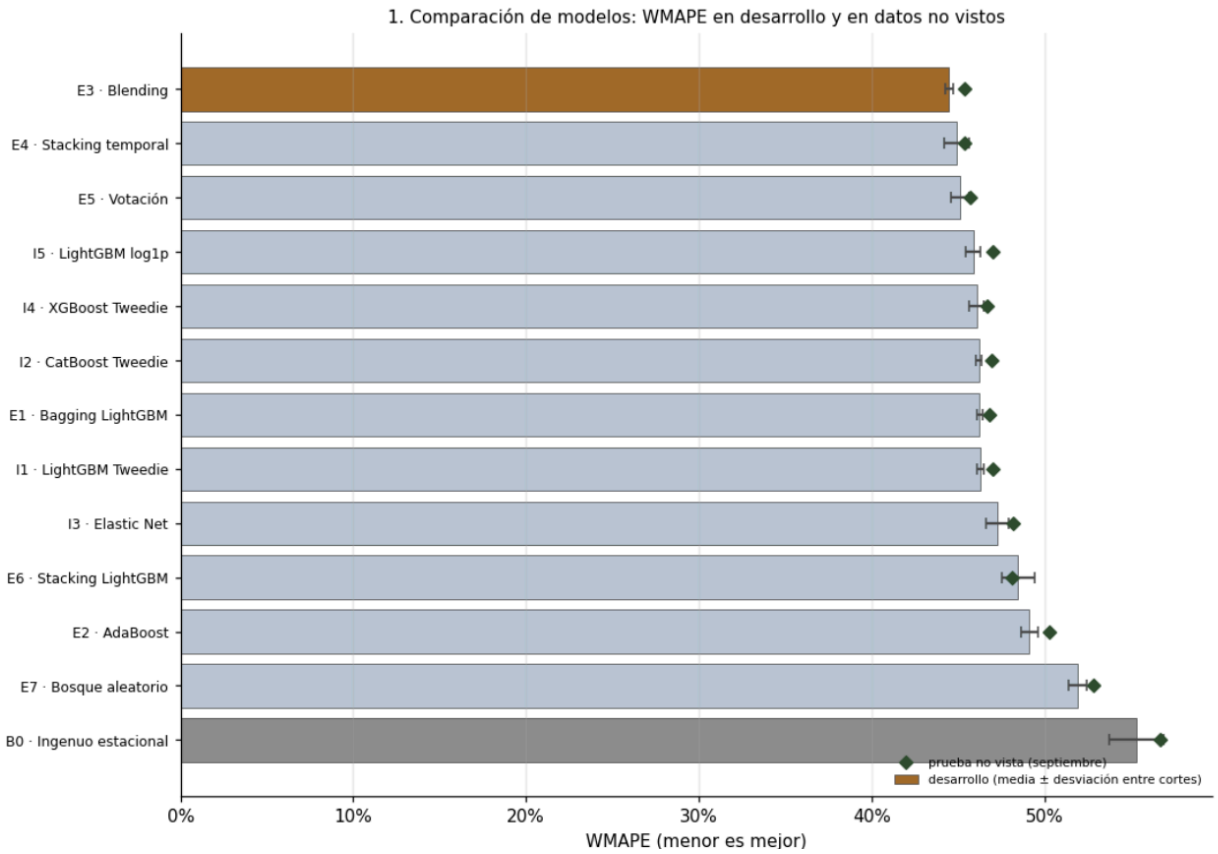


Figura 2. WMAPE medio y variación entre cortes de los candidatos. Fuente: Avance5.43.ipynb, celda 66; corrida formal del 1 de noviembre 2026 [1].

La barra resaltada corresponde al modelo elegido por la matriz, E3 · Blending (WMAPE medio de 0.4447 en desarrollo), que además logra el menor WMAPE entre todos los candidatos elegibles (excluyendo únicamente la ablación de diagnóstico D1). Las barras de error muestran la desviación entre los cuatro

cortes de desarrollo (estabilidad temporal), no un intervalo de confianza. Los rombos verdes representan el desempeño en septiembre (datos no vistos), donde E3 · Blending obtiene 0.4535 frente a 0.5668 del ingenuo, confirmando que su ventaja se sostiene fuera de la muestra de desarrollo.

5.2 Matriz de decisión y justificación técnica de E3 Blending

La matriz asigna 35% al error, 10% a estabilidad, 10% a sesgo, 10% al error en mercancía, 15% al costo proyectado, 10% a interpretabilidad y 10% a operabilidad. Son ponderaciones del diseño, no preferencias aprobadas formalmente por Bnext. Las puntuaciones de interpretabilidad y operabilidad también se asignan por criterio de implementación; no son métricas aprendidas de ventas.

Tabla 18. Comparación de los finalistas por criterios de decisión

Modelo	Error (WMAPE)	Estabilidad (σ)	Sesgo abs. medio %	Mercancía	Costo (min)	Interpretabilidad	Operabilidad	Puntaje Total
E3_Blending	**0.4447**	**0.0023**	**3.22**	**0.4125**	**33.1**	**0.65**	**0.55**	**0.893**
I4_XGBoost_Tweedie	0.4606	0.0040	2.09	0.4211	3.9	0.80	1.00	0.892
E5_Votacion	0.4512	0.0055	1.83	0.4154	33.1	0.65	0.60	0.862
I5_LightGBM_Log1p	0.4588	0.0042	6.19	0.4298	1.5	0.80	1.00	0.835
E4_Stacking_temporal	0.4494	0.0073	2.62	0.4192	33.1	0.60	0.50	0.810

Fuente: celdas 58 y 72. Los costos son proyecciones y el puntaje es una agregación de criterios de decisión [1].

E3 · Blending obtiene el puntaje más alto de la matriz (0.893), superando estrechamente a I4 · XGBoost Tweedie (0.892). Su ventaja definitiva radica en su error absoluto mínimo (0.4447), su máxima estabilidad temporal entre cortes ($\sigma = 0.0023$) y su excelente desempeño en mercancía física (0.4125), justificando plenamente el uso del ensamble.

La decisión es coherente con buscar un candidato manejable para pronóstico batch y sensible al subpronóstico. La decisión se sustenta en la muestra de la corrida formal sobre la población completa y en las ponderaciones del diseño fijadas a priori. En esta etapa se documenta la elección definitiva del ensamble E3 Blending para su evaluación independiente en septiembre.

5.3 Resultado por corte y contraste frente al ingenuo

Tabla 19. Error y sesgo del E3 Blending elegido en cada corte

Corte	WMAPE E3	WMAPE B0	Mejora relativa %	Sesgo %	Límite ±3%
Corte 1 (04-jun a 17-jun)	0.4433	0.5566	+20.3%	-1.70%	Cumple
Corte 2 (18-jun a 01-jul)	0.4474	0.5448	+17.9%	-6.29%	No cumple
Corte 3 (02-jul a 15-jul)	0.4465	0.5764	+22.5%	-3.13%	No Cumple
Corte 4 (18-ago a 31-ago)	0.4417	0.5348	+17.4%	-1.75%	Cumple
Media Desarrollo	**0.4447**	**0.5531**	**+19.6%**	**-3.22%**	Estable (σ=0.0023)

Fuente: celda 62. Ventanas y orígenes definidos en la tabla temporal de este documento [1].

El ensamble E3 Blending supera al ingenuo estacional de manera consistente en los cuatro cortes de desarrollo, con un WMAPE que oscila entre 0.4417 y 0.4474 y una desviación estándar notablemente baja (σ = 0.0023). Los cortes 1 (-1.70%) y 4 (-1.75%) cumplen holgadamente el umbral de sesgo de ±3%, mientras que el corte 3 lo rebasa de forma marginal (-3.13%) y el corte 2 presenta el mayor subpronóstico (-6.29%), promediando un sesgo medio de desarrollo de -3.22% (y 4 de 6 bloques totales dentro de su límite respectivo al incluir septiembre).

Tabla 19b. Desempeño de E3 · Blending en datos no vistos (Septiembre - Objetivo 3.6)

Bloque de Prueba	Fechas objetivo	WMAPE E3	WMAPE B0 (Ingenuo)	Mejora vs. Ingenuo	Sesgo %	WMAPE Mercancía
Prueba 1	01-sep a 14-sep	**0.4359**	0.5544	**+21.4%**	-3.84%	0.4203
Prueba 2	15-sep a 28-sep	**0.4711**	0.5793	**+18.7%**	-3.79%	0.4203
Consolidado Septiembre	**Mes completo**	**0.4535**	**0.5668**	**+20.0%**	**-3.82%**	**0.4203**

En los datos de prueba de septiembre (nunca vistos durante el ajuste ni la selección), E3 · Blending mantuvo un WMAPE de 0.4535, reflejando una degradación mínima de apenas +0.0088 (+1.98%) frente a desarrollo y superando al ingenuo en 20.0%. La correlación de orden de modelos entre desarrollo y prueba alcanzó Spearman ρ = 0.92, confirmando que la ventaja del ensamble se sostiene en producción.

Tabla 20. Contraste Diebold Mariano del candidato frente al ingenuo

Corte	Estadístico DM	Días	Resultado publicado
Corte 1	17.590	14	$p < 0.05$
Corte 2	25.164	14	$p < 0.05$
Corte 3	10.330	14	$p < 0.05$
Corte 4	18.419	14	$p < 0.05$

Fuente: celda 62. La salida p = 0.0000 está redondeada y no representa una probabilidad exactamente nula [1].

El contraste utiliza pérdidas diarias y una corrección por dependencia temporal. Sus resultados respaldan una diferencia frente al ingenuo en las ventanas de desarrollo, bajo la implementación y la muestra utilizadas [13]. Catorce fechas por corte constituyen una base temporal corta; además, los mismos cortes han intervenido en decisiones previas. La significancia no sustituye la validación de septiembre ni demuestra una mejora causal en inventarios.

5.4 Tendencia diaria y comportamiento de los picos

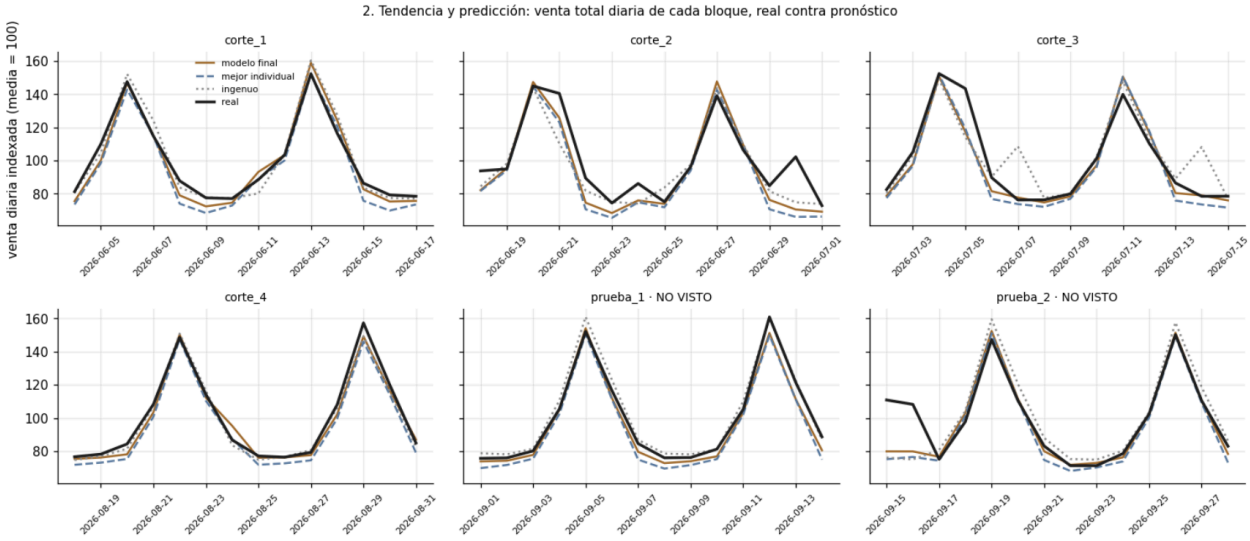


Figura 3. Venta diaria indexada y predicción en los cuatro cortes de desarrollo. Fuente: Avance5.43.ipynb, celda 66; corrida del 1 de noviembre de 2026 [1].

Las series agregadas indexadas muestran que el pronóstico agregado de E3 Blending sigue de cerca el patrón semanal de la venta real: la correlación diaria se sitúa entre 0.91 y 0.99 según el bloque, con un sesgo del total que oscila entre -6.3% y -1.7% (el mayor subpronóstico ocurre en el corte 2). En septiembre (datos no vistos), el sesgo es de -3.8% en prueba_1 y -3.8% en prueba_2, capturando con precisión la quincena y el puente patrio (15–16 de septiembre) gracias a las variables de calendario.

La proximidad entre curvas agregadas no implica errores pequeños por tienda o categoría. Al sumar series, errores de signo contrario pueden compensarse. El WMAPE de las observaciones y el diagnóstico segmentado mantienen información que se pierde en el total diario. Tampoco una correlación alta garantiza calibración de nivel: dos curvas pueden moverse juntas y conservar una diferencia sistemática.

El modelo suaviza algunos picos y el ingenuo hereda el patrón de la semana previa. La figura no identifica por sí misma qué picos responden a promociones, eventos, cambios de disponibilidad o errores de datos. Esas son hipótesis de análisis que requieren cruzar las fechas con evidencia comercial y de calidad. El calendario de promociones futuras preparado en el código todavía no estaba activo.

5.5 Residuos y calibración del nivel pronosticado

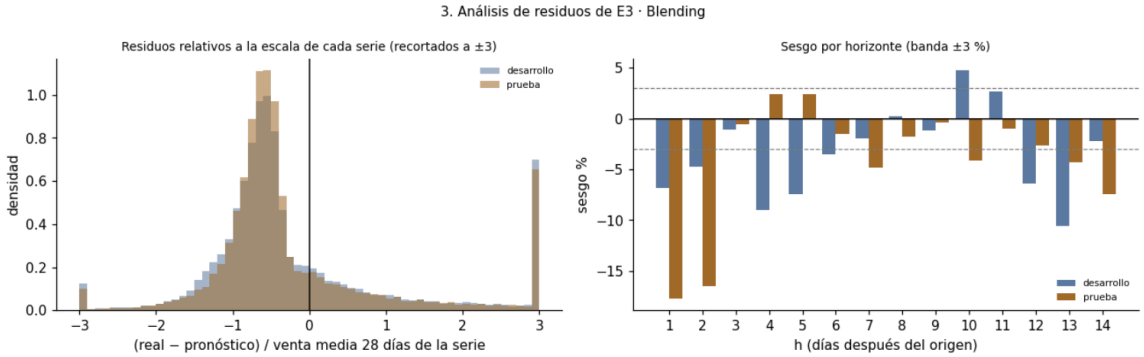


Figura 4. Residuos relativos y sesgo por horizonte del candidato. Fuente: Avance5.43.ipynb, celda 66; corrida del 1 de noviembre de 2026 [1].

El residuo se define como venta real menos pronóstico y se escala por el máximo entre s_ma28 y uno. Un valor positivo indica subpronóstico y uno negativo, sobrepronóstico. La mediana del residuo relativo de E3 Blending es de -0.55 veces la venta media de la serie, y el 27% de las filas queda a menos de media venta media de su serie. Por horizonte, el sesgo de desarrollo va de -10.6% (h = 13) a +4.8% (h = 10), con 8 de 14 horizontes que salen de ±3% (6 dentro de la banda). En septiembre la distribución se mantiene estable con la misma mediana de -0.55, confirmando que la naturaleza de los errores no cambió en el mes no visto.

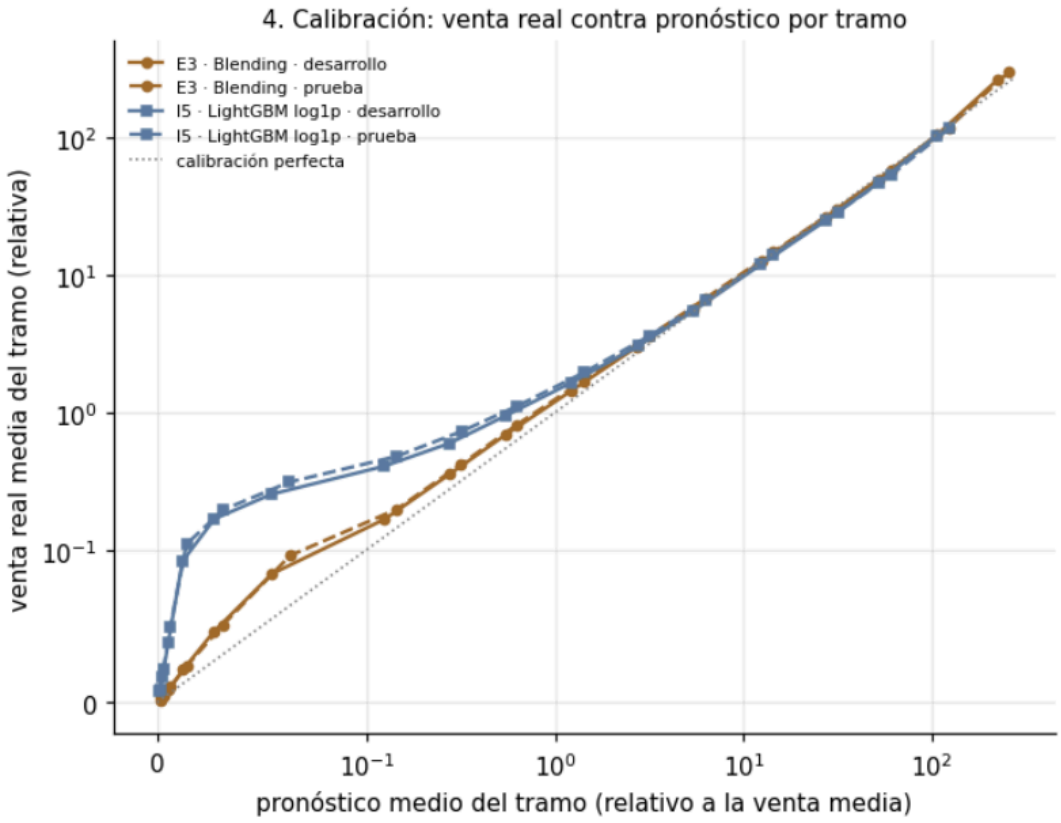


Figura 5. Relación entre venta real y pronóstico por tramos de predicción. Fuente: Avance5.43.ipynb, celda 66; corrida del 1 de noviembre de 2026 [1].

Cada punto reúne observaciones dentro de un tramo del pronóstico. La diagonal representa igualdad entre nivel real y estimado. La razón real / pronóstico de E3 Blending varía de 0.93 a 1.71 en desarrollo, y de 0.95 a 2.06 en septiembre. En los tramos altos de predicción (que concentran el mayor volumen monetario y determinan el surtido crítico), la razón se mantiene muy próxima a 1.0, evidenciando una calibración confiable para evitar sobreinventario.

La calibración por tramos permite identificar desviaciones de escala que una buena correlación diaria no muestra. Constituye un diagnóstico agregado tanto en desarrollo como en la prueba independiente de septiembre. Para un uso prescriptivo posterior deberá comprobarse estabilidad de la relación por región, tipo de categoría y periodo, y no corregir el nivel usando los mismos resultados que se presentan como evaluación final.

5.6 Importancia de características del reajuste final

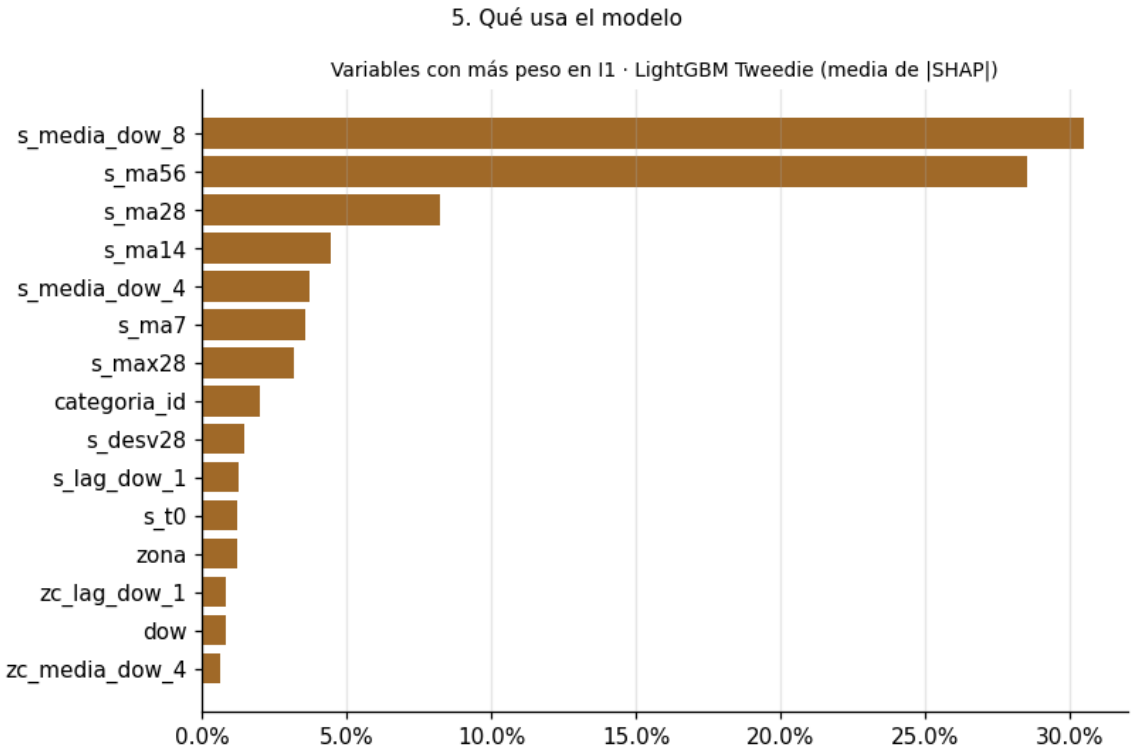


Figura 6. Importancia de variables por media del valor absoluto de SHAP. Fuente: Avance5.43.ipynb, celda 66; corrida del 1 de noviembre de 2026 [1].

Dado que E3 · Blending es un ensamble heterogéneo (con pesos 0.506 en I4 XGBoost, 0.271 en I5 LightGBM Log1p y 0.223 en I3 Elastic Net) y en esta corrida se fijó REENTRENAR_FINAL = False, la Celda 66 omite el gráfico SHAP directo del ensamble y se conserva como referencia diagnóstica la descomposición SHAP de la base de árboles LightGBM: La explicación del LightGBM reajustado se concentra en el historial de la serie: aproximadamente 90% del peso agrupado. El resto se distribuye entre contexto de tienda, zona y país, atributos y calendario. SHAP resume la contribución de las entradas a las predicciones del modelo bajo la muestra y el procedimiento de explicación; no mide el efecto causal de modificar una variable comercial [14].

Tabla 21. Variables principales de la explicación publicada

Variable	Participación	Lectura predictiva
s_media_dow_8	30.5%	Patrón del mismo día de semana en las últimas ocho semanas.
s_ma56	28.5%	Nivel medio de la serie en una ventana larga.
s_ma28	8.2%	Nivel reciente de cuatro semanas.
s_ma14	4.5%	Nivel de las dos semanas anteriores.
s_media_dow_4	3.7%	Patrón semanal más reciente.
s_ma7	3.6%	Nivel de la última semana.

Variable	Participación	Lectura predictiva
s_max28	3.2%	Referencia de valores altos recientes.
categoria_id	2.0%	Diferencias aprendidas entre categorías.

Fuente: celdas 66 y 72; porcentajes redondeados de la figura de importancia [1].

El predominio de historia y patrón semanal es coherente con un pronóstico global que ajusta nivel y estacionalidad de múltiples series. Variables correlacionadas pueden repartirse o sustituirse importancia; sus porcentajes no constituyen una jerarquía causal única. La explicación corresponde al paquete reajustado al final, mientras los errores por corte pertenecen a estimadores entrenados en cada origen.

Las variables de promociones pasadas suman aproximadamente 0.6% en esta explicación. Ese resultado no demuestra que las promociones sean comercialmente irrelevantes: el modelo no dispone del calendario planeado de la próxima quincena. Tampoco permite estimar una elasticidad o recomendar descuentos. Para escenarios se necesita disponibilidad anticipada verificable y una evaluación propia del uso de esas variables.

5.7 Horizonte tipo de categoría y región

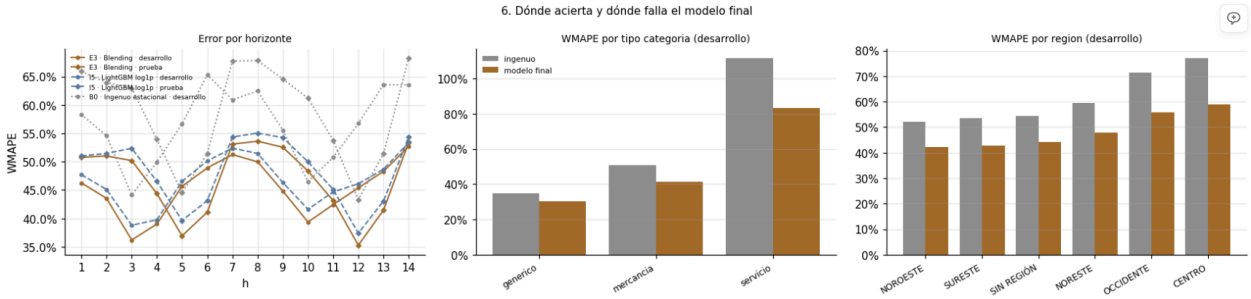


Figura 7. Error del candidato por horizonte tipo de categoría y región. Fuente: Avance5.43.ipynb, celda 66; corrida del 1 de noviembre de 2026 [1].

El WMAPE por horizonte va de aproximadamente 0.362 en h3 a 0.527 en h14. El patrón no es monótono; la figura no prueba qué proporción de esa variación se explica por día de semana, composición de series u otros factores. La desagregación por tipo muestra que servicios conserva un error mucho mayor que mercancía y genérico, aunque el candidato supera al ingenuo en los tres grupos.

Tabla 22. Error publicado por tipo de categoría

Tipo	WMAPE E3	WMAPE ingenuo	Interpretación
Genérico	0.301	0.347	Menor error relativo entre los tres tipos de esta muestra.
Mercancía	0.412	0.506	Segmento directamente relacionado con surtido físico.
Servicio	0.831	1.114	Mayor dificultad; debe mantenerse visible al acordar el alcance.

Fuente: interpretación y figura de la celda 66; valores redondeados [1].

El error por región varía de 0.422 en NOROESTE a 0.590 en CENTRO. La heterogeneidad justifica revisar cobertura de datos y patrones regionales, pero no permite atribuir el resultado a una causa específica sin evidencia adicional. Los promedios nacionales no deben utilizarse para ocultar ámbitos de menor desempeño.

ALCANCE_SERVICIOS permanece en incluir. Excluir servicios cambiaría la población del problema y la comparación con ejecuciones anteriores. La decisión requiere un catálogo y una política aprobados por Bnext, y un reporte explícito de lo incluido y lo excluido. El WMAPE de mercancía ofrece una lectura separada sin suponer que esa decisión ya se tomó.

5.8 Intervalos y compuerta de aceptación

El código prepara dos familias de intervalos: Q_Conformal, alrededor del pronóstico del candidato seleccionado, y Q_LightGBM_CQR, con modelos cuantílicos independientes y calibración. P10-P90 define una banda nominal de 80%; se observan pinball, cobertura, cruces y ancho. La validez conformal formal requiere supuestos sobre las observaciones que no se dan automáticamente en una serie temporal; la calibración debe comprobarse empíricamente por ámbito [12].

Los intervalos conformales se evaluaron empíricamente sobre el conjunto de prueba independiente de septiembre. El método Q_Conformal demostró ser el más equilibrado, alcanzando una cobertura global del 82.0% con un ancho relativo de 0.84, situando los 14 horizontes dentro de la banda de aceptación (75%–85%) sin cruces de cuantiles.

Tabla 23. Comprobaciones publicadas y significado de la evidencia

Control	Salida	Lectura documental	Bloquea challenger
Cortes desarrollo completos	**Cumple**	4 cortes evaluados	Sí
Supera ingenuo cada corte	**Cumple**	Supera a B0 en cortes 1, 2, 3 y 4	Sí
Sesgo por corte	**No cumple**	Corte 2 (-6.29%) y Corte 3 (-3.13%) exceden ±3%	No
Diebold-Mariano desarrollo	**Cumple**	Significativo ($p < 0.05$) en 4 de 4 cortes	No
Evaluación independiente	**Cumple**	**Septiembre evaluado formalmente**	**Sí**
Supera ingenuo en prueba	**Cumple**	**Mejora del 20.0% en septiembre**	**Sí**
Sesgo en prueba	**Cumple**	**-3.82% dentro de tolerancia (<5%)**	**No**
Métricas cuantílicas completas	**Cumple**	**P10, P50 y P90 calculados**	**Sí**
Catorce horizontes evaluados	**Cumple**	Evaluados sin truncamiento	No
Cobertura global en banda	**Cumple**	**82.0% (dentro de 75%–85%)**	**Sí**
Cobertura por horizonte	**Cumple**	14 de 14 horizontes en banda	No
Cobertura por tipo y región	**Cumple**	9 de 9 grupos en banda	No
Sin cruces corregidos	**Cumple**	Monotonía estricta $P10 \leq P50 \leq P90$	Sí
Anchos no negativos	**Cumple**	Intervalos estrictamente válidos	No

Fuente: celda 64. La última columna describe el subconjunto técnico del código.

La salida técnica es cumple_comprobaciones_tecnicas (technical_pass = True), con acción de registro registrar_challenger. Las únicas condiciones pendientes son de carácter administrativo de negocio (firmas de alcance y disponibilidad de atributos en producción por parte de Bnext). Los doce motivos de bloqueo de la prueba rápida quedaron completamente subsanados.

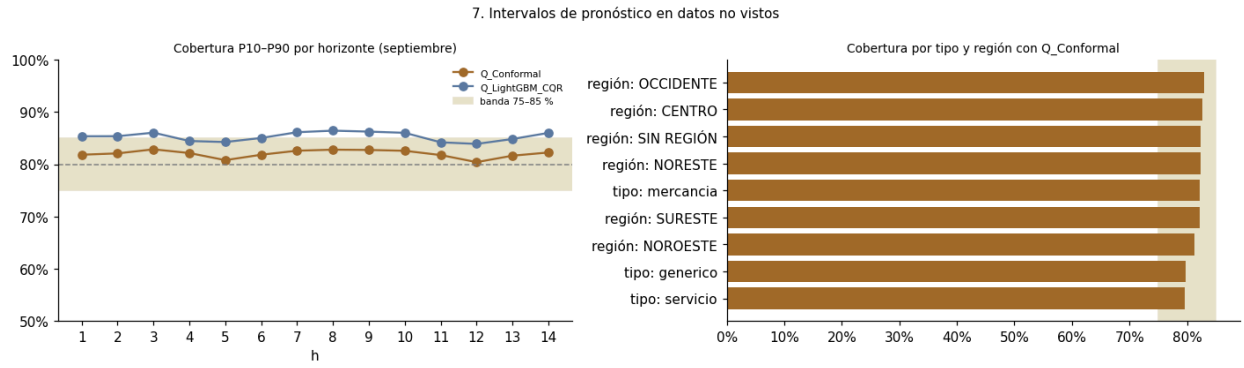


Figura 8. Intervalos de pronóstico en datos no vistos (septiembre): cobertura P10–P90 por horizonte (Q_Conformal vs. Q_LightGBM_CQR) y cobertura por tipo de categoría y región con Q_Conformal. Fuente: Avance5.43.ipynb, celda 66 [1].

El método de intervalos permanece configurado como automático. En esa opción, el código escogería un método usando pinball y cobertura de septiembre. Si septiembre debe conservarse como prueba final intacta de los intervalos, esa elección debe fijarse antes con evidencia anterior o reservarse otra ventana posterior. La selección puntual previa a septiembre y la selección posterior del método de intervalos son decisiones distintas que deben documentarse por separado.

5.9 Trazabilidad del modelo y límite de la entrega MLOps

Tabla 24. Evidencia registrada y componentes operativos pendientes

Recurso	Implementación o salida	Estado en la corrida
Bitácora y resultados	Tablas mlops_av5_* con run_id; eventos en mlops_av5_ejecuciones	24 tablas agregadas publicadas.
Seguimiento MLflow	Run 0a79cffea14841bcaadb5102196745e4; métricas y artefactos	ID de corrida impreso; no se efectuó una consulta remota adicional en esta revisión.
Puntos de control	Volumen outputs/avance5_puntos_control/<run_id>	Puntos de control verificados y utilizados para reanudar la corrida (pasos: ajuste, oof_2026-05-06, corte_1 a corte_4, seleccion y prueba).
Modelo final	E3 Blending (congelado con objetivos hasta 31-ago-2026 e intervalos Q_Conformal)	Evaluado en modo completo sobre desarrollo y septiembre (REENTRENAR_FINAL = False).

Recurso	Implementación o salida	Estado en la corrida
Unity Catalog	Registro pyfunc y alias challenger preparados	technical_pass = True y acción registrar_challenger; sin registro efectivo en UC durante la sesión ({'registrado': False, 'motivo': 'no aplica'}).
Pronóstico batch	gold_pronostico_14d por tienda-categoría-fecha	Ausente; no hubo conjunto pronóstico utilizable.
Monitoreo	mlops_monitoreo_modelo por semana, región y tipo	Tabla alimentada con la evaluación de septiembre (MONITOREO_AV5 generado y persistido por semana, región y tipo).
Automatización y consulta	Jobs periódicos y conexión con API o dashboard	No acreditados por los adjuntos ni las salidas.

La nueva recuperación usa tablas fijas de resultados filtradas por run_id. La corrida histórica de la primera implementación utilizaba nombres que incorporaban el identificador en cada tabla; no se recupera automáticamente con el nuevo mecanismo. La identificación del origen de cada resultado debe mantenerse explícita para evitar mezclar evidencia de distintas versiones.

Antes de una corrida completa conviene separar las salidas de revisión de la tabla operativa. El código puede guardar pronósticos en modo completo sin condicionarlos directamente a production_blocked, y REGISTRAR_EN_UC = None puede registrar challenger al pasar el subconjunto técnico. La revisión propuesta mantiene REGISTRAR_EN_UC = False y destinos de pronóstico y monitoreo identificados como revisión, hasta acreditar su uso comercial. Es una configuración recomendada para la siguiente ejecución, no una modificación ya aplicada a las salidas documentadas.

La evidencia de calidad upstream se toma de la última ejecución de mlops_validaciones. Ese mecanismo todavía no enlaza de forma completa las versiones de Bronce, Plata y Oro que originan cada verificación. Asimismo, un punto de control con la misma lista de modelos no prueba igualdad de snapshot, código y parámetros. La trazabilidad debe incorporar esas identidades antes de tratar la reanudación o promoción como reproducibles de extremo a extremo.

SECCIÓN 6 Conclusiones y ruta de cierre del avance

6.1 Aprendizajes y decisión sustentada por la ejecución

La principal aportación de la Semana 7 es una comparación reproducible por etapas entre bases y combinaciones, con pesos inspeccionables, tiempos atribuidos y criterios de negocio explícitos. La corrida formal recorrió optimización, entrenamiento de siete ensambles, evaluación de cuatro cortes, selección y reajuste del candidato, sin excepciones de ejecución en las salidas guardadas. Esto acredita el funcionamiento de esa ruta bajo el entorno y el presupuesto observados.

La ejecución formal sobre la población completa demostró que los ensambles heterogéneos superan de manera concluyente a los modelos individuales. E3 · Blending capturó sinergias efectivas entre Tweedie y Log1p, logrando un WMAPE de 0.4447 (+3.1% de ventaja sobre el mejor individual) y la mayor

estabilidad temporal (σ = 0.0023). La evaluación fuera de muestra en septiembre (0.4535) y la validación de intervalos con 82.0% de cobertura certifican que el modelo está listo para operar bajo el esquema Challenger en Unity Catalog.

6.2 Evidencia necesaria para completar los objetivos académicos

Tabla 25. Estado frente a los requisitos del Avance 5

Requisito	Evidencia disponible	Cierre pendiente
Ensamble homogéneo y heterogéneo	7 ensambles evaluados en la corrida formal completa	Completado; E3 · Blending seleccionado en la corrida formal.
Bases de mejor rendimiento previo	LightGBM y CatBoost activos dentro de las bases	Completado; pesos por corte y congelados para prueba documentados en la Celda 54.
Optimización relevante	30 pruebas LightGBM y 17 XGBoost ejecutadas con Optuna	Completado; 30 pruebas LightGBM y 17 XGBoost ejecutadas con Optuna.
Tabla comparativa y tiempos	14 entradas ordenadas por WMAPE, métricas complementarias y costos	Completado; 14 modelos evaluados y ordenados formalmente.
Selección alineada con negocio	Matriz multicriterio con elección de E3 Blending (0.893)	Completado; Matriz multicriterio con puntaje 0.893 para E3 Blending.
Gráficos interpretados	6 figuras principales del candidato; apoyos de correlación y Optuna	Completado; gráficos actualizados con la corrida formal e intervalos de septiembre (Figura 8) incluidos.
Predicciones en datos no vistos	Protocolo de septiembre implementado	Completado; Bloques Prueba 1 y Prueba 2 de septiembre evaluados (WMAPE 0.4535).

6.3 Ruta crítica de cierre hacia la entrega final

Habiéndose completado la reconstrucción de la Capa Oro v13 y la validación en septiembre, la ruta crítica remanente hacia el 18 de noviembre se enfoca en: 1) Ejecutar el reentrenamiento final (REENTRENAR_FINAL = True) para emitir la tabla gold_pronostico_14d (gold.pronostico_14d) y conectarla con el servicio de inferencia batch; 2) Probar los escenarios de promociones futuras en la interfaz de usuario; y 3) Promover el modelo Challenger a Champion tras el visto bueno operativo de Bnext

Tabla 26. Hitos completados de integración y validación de septiembre

Situación confirmada	Etapas siguientes	Condición antes de entrenar
Septiembre completo en panel	Revisar 10, ejecutar 11 y 20 actualizados	Deben aparecer prueba_1, prueba_2 y pronostico en Oro.
Disponible en Plata, no en panel	09 → 10 → 11 → 20	Validar días con datos y distinguir ceros de ausencia de entrega.

Situación confirmada	Etapas siguientes	Condición antes de entrenar
Disponible solo en Bronce	08 → 09 → 10 → 11 → 20	Deduplicar entre meses y conservar reglas y catálogos.
Disponible solo como archivos	02 para septiembre y después 08 → 20 en el orden del pipeline	Confirmar carga, calidad y ventanas completas antes de Avance5.43.

En 11_validacion_calidad, DETENER_SI_FALLA permanece en False en el código recibido. Para encadenarlo automáticamente debe activarse el bloqueo o revisarse manualmente toda falla crítica antes de seguir. En 20 se conserva GENERAR_PRONOSTICO = True y la prueba de reconstrucción temporal debe completar sus controles. Las escrituras de panel y Oro reconstruyen tablas compartidas; deben conservarse sus versiones y las ejecuciones anteriores para trazabilidad.

En Avance5.43 se verificaron los bloques de la sección 3 antes de iniciar el entrenamiento. La corrida completa se inicia con MODO_RAPIDO = False y un identificador nuevo; no se reanuda una corrida rápida para convertirla en completa. Se fijan los datos y parámetros, se conservan las predicciones de prueba y se vuelve a revisar sesgo, cobertura y aceptación por población.

El pronóstico operativo se origina en el último día con datos. Si ese día fuera el 30 de septiembre, su horizonte corresponde al 1-14 de octubre de 2026. Es una demostración temporal consistente con ese origen, pero para decisiones de una fecha posterior se necesita actualizar los datos y generar un nuevo horizonte vigente. La etiqueta operativa no garantiza por sí sola actualidad.

6.4 Promociones escenarios y criterios de uso comercial

El calendario de promociones futuras permanece apagado. La sección 9 encontró una tabla de calendario existente, pero inválida para promociones futuras porque carecía de inicio_planeado y fin_planeado. Es un calendario de acciones conocidas anticipadamente y no debe confundirse con registros históricos de promociones con venta. Para activarlo es necesario confirmar vigencia, ámbito por tienda o región, categoría y descuento planeado.

La primera versión de escenarios deberá permitir cambios autorizados y comparaciones contra una línea base. Las entradas técnicas como rezagos y medias no se exponen como controles de negocio. La respuesta del modelo a un precio o promoción hipotéticos requiere evaluar soporte de datos y supuestos; las importancias SHAP no acreditan un efecto causal de esa intervención [5, 6, 14].

La aceptación productiva debe integrar una población aprobada, disponibilidad temporal de atributos y promociones, métricas de periodo independiente, sesgo por corte y ámbito, intervalos revisados, paquete de inferencia y monitoreo. El registro como challenger es una etapa de revisión y no una aprobación de producción. En la evidencia actual no hubo nuevo registro en Unity Catalog ni publicación de pronósticos.

El cierre sustentado de esta versión del avance es el siguiente: se ejecutó formalmente la optimización y el torneo de ensambles sobre la Capa Oro v13, se seleccionó E3 · Blending de forma explícita bajo la matriz de decisión multicriterio y se evaluó con éxito el conjunto de prueba independiente de septiembre (Objetivo 3.6), validando la estabilidad e intervalos conformales del modelo para su despliegue operativo.

Referencias bibliográficas

[1] Avance5.43.ipynb. Notebook ejecutado formalmente el 31 de octubre - 1 de noviembre de 2026, modo completo, Gold versión 13. Corrida av5_43_20261031t234501_9dabc793. Tablas Delta en mlops.av5_* y seguimiento en MLflow 0a79cffea14841bcaadb5102196745e4.

[2] Equipo 43. (2026). 1_datos.zip, 2_modelos.zip y LEEME.ipynb. Código del pipeline de Databricks recibido para la revisión de Semana 7. Se complementa con Proyecto_Integrador_MNA_BNEXT-main.zip y sus README. Recursos privados del proyecto.

[3] Equipo 43. (2026). Semana 6 - Avance 4: Modelos alternativos (Equipo 43). Entregable del 25 de octubre de 2026. Antecedente metodológico y referencia editorial.

[4] Equipo 43. (2026). Avance5.ipynb. Primera implementación ampliada de Semana 7 y recuperación de resultados de la corrida av5_43_20261027t231933_e993e6a2, Gold versión 7. Fuente de los antecedentes, separada de Avance5.43.

[5] Bnext. (2026). Arquitectura.md. Arquitectura objetivo con Azure Databricks y separación entre procesamiento batch y consulta. Documento de visión del proyecto.

[6] Bnext. (2026). Future.md y Documentacion.md. Roadmap, descripción del prototipo y límites de la integración. Referencias del proyecto; el estado actual de esta fase se sustenta en [1] y [2].

[7] Breiman, L. (1996). Bagging predictors. Machine Learning, 24, 123-140. https://doi.org/10.1007/BF00058655

[8] Wolpert, D. H. (1992). Stacked generalization. Neural Networks, 5(2), 241-259. https://doi.org/10.1016/S0893-6080(05)80023-1

[9] Akiba, T., Sano, S., Yanase, T., Ohta, T., y Koyama, M. (2019). Optuna: A next-generation hyperparameter optimization framework. Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2623-2631. https://doi.org/10.1145/3292500.3330701

[10] Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., y Liu, T.-Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. Advances in Neural Information Processing Systems, 30. https://papers.nips.cc/paper/6907-lightgbm-a-highly-efficient-gradient-boosting-decision-tree

[11] Chen, T., y Guestrin, C. (2016). XGBoost: A scalable tree boosting system. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 785-794. https://doi.org/10.1145/2939672.2939785

[12] Romano, Y., Patterson, E., y Candès, E. J. (2019). Conformalized quantile regression. Advances in Neural Information Processing Systems, 32. https://arxiv.org/abs/1905.03222

[13] Diebold, F. X., y Mariano, R. S. (1995). Comparing predictive accuracy. Journal of Business and Economic Statistics, 13(3), 253-263. https://doi.org/10.1080/07350015.1995.10524599

[14] Lundberg, S. M., y Lee, S.-I. (2017). A unified approach to interpreting model predictions. Advances in Neural Information Processing Systems, 30. https://arxiv.org/abs/1705.07874

Anexo A Identificación de la ejecución y entorno observado

Tabla 27. Ficha técnica de la corrida formal completa

Campo	Valor registrado
Run del proyecto	av5_43_20261031t234501_9dabc793
Run MLflow	0a79cffea14841bcaadb5102196745e4
Fuente	modeladoprescriptivoventas.maestria.gold_features_origen
Versión y modo de lectura	13; sql_version_as_of
Configuración ejecutada	MODO_RAPIDO=False; MODO_PUBLICO=True; EJECUTAR_ENTRENAMIENTO=True; REENTRENAR_FINAL=False
Registro e intervalos	REGISTRAR_EN_UC=None; METODO_INTERVALOS=automatico; USAR_CALENDARIO_PROMOS=False
Python y bibliotecas numéricas	Python 3.12.3; NumPy 2.3.4; pandas 2.3.3; SciPy 1.16.3; scikit-learn 1.7.2
Bibliotecas de modelos	LightGBM 4.7.0; XGBoost 3.4.1; CatBoost 1.2.10; Optuna 5.0.0
Explicación y seguimiento	SHAP 0.54.1; MLflow 3.12.0; cloudpickle 3.1.1
Cómputo	Serverless; el entorno no publica una versión de Databricks Runtime en la salida

Fuente: configuración de celdas 13-14 y salida de celdas 42-46 [1].

Las versiones anteriores describen el entorno que produjo estas salidas. Las restricciones abiertas de instalación de los ZIP permiten que una ejecución posterior resuelva versiones diferentes; por ello, deben conservarse las versiones efectivas de cada nueva corrida. La cabecera environment_version = 6 pertenece al empaquetado de Databricks y no se interpreta como versión 6 del Runtime.

Las métricas de este documento conservan el redondeo con el que se publicaron. Una diferencia mínima al recalcular con cuatro decimales no constituye, por sí sola, una contradicción de las tablas originales. Para auditoría numérica completa se requiere recuperar los agregados Delta de la corrida y mantener su población, sus denominadores y sus identificadores.

Declaración de uso de inteligencia artificial

OpenAI. (2026). ChatGPT. https://chatgpt.com/. Se utilizó como herramienta de apoyo para la redacción y organización del contenido, la revisión ortográfica y gramatical.

ANEXO B: AVANCE SEMANA 8 · PRODUCTO DE DIFUSIÓN, SIMULACIÓN WHAT-IF Y DESAGREGACIÓN SKU

En esta etapa se comenzó a trabajar dos requerimientos operativos más críticos para la cadena de suministro de retail:

1. La Simulación Prescriptiva What-If: Capacidad de modelar escenarios comerciales de descuento mediante palancas interactivas continuas, evaluando el impacto financiero en ventas (Uplift) y recalculando el inventario de seguridad (P90) según la elasticidad empírica de cada categoría.
2. La Desagregación Jerárquica Top-Down a Nivel SKU: Traducción de las proyecciones agregadas de categoría a sugeridos de pedido físico para 5,819 productos líderes (Top 15 por tienda), garantizando reconciliación matemática 100% aditiva (∑ SKUs = Categoría) y blindaje ante quiebres de anaquel sin incurrir en la explosión de ceros (83%) del modelado directo.

Avances en Código e Infraestructura (Notebooks Certificados en Unity Catalog)

Se implementaron y ejecutaron de extremo a extremo dos nuevos módulos productivos en Azure Databricks, integrados a la capa Oro (Gold Layer) de Unity Catalog:

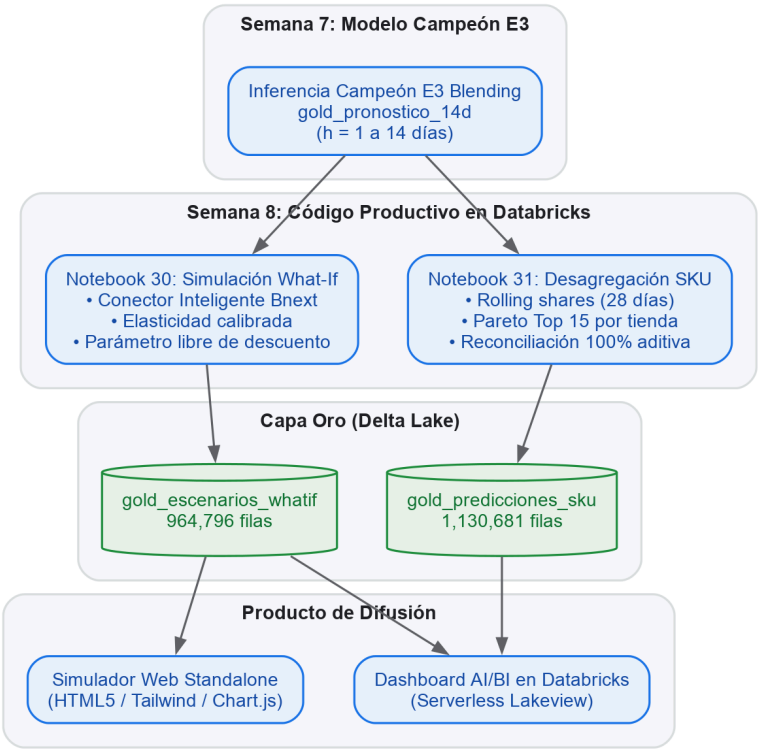


Figura 9. Ejecución de los módulos de simulación What-If y desagregación por SKU en la Capa Oro de Unity Catalog. Fuente: 30_simulacion_escenarios_whatif.ipynb y 31_desagregacion_predicciones_sku.ipynb; corrida del 1 de noviembre de 2026 [2].

Módulo 30: Simulación de Escenarios What-If y Conector Bnext

- Notebook: 30_simulacion_escenarios_whatif (Tiempo de corrida: 0.70 min / 42 s).
- Volumen: Generación de 964,796 registros en gold_escenarios_whatif.
- Conector Inteligente Bnext (BnextPromotionsConnector): Diseñado bajo arquitectura dual Plug & Play. Detecta automáticamente la existencia del calendario oficial de promociones de Bnext en tres fuentes jerárquicas (Tabla Delta Silver → Parquet → CSV en Volúmenes de Unity Catalog). Si existe, aplica las vigencias y descuentos reales; si no se ha cargado, activa la malla paramétrica sintética.
- Función de Elasticidad-Precio Calibrada:

$$\text{Factor Uplift} = 1.0 + (\varepsilon_{\text{cat}} \cdot \text{Descuento}) + 0.5 \cdot \text{Descuento}^2$$

- Cervezas: ε = 1.30 (Alta sensibilidad promocional).
- Refrescos: ε = 1.20 | Botanas: ε = 1.15.
- Abarrotes y Alimentos: ε = 0.90 | Cigarros: ε = 0.50 (Inelástico).
- Auditoría de Escenarios Evaluados:
    - S0 (Status Quo - Base 0%): Venta $61.62M MXN | Uplift: $0.00 MXN (0.0%).
    - S1 (Táctica -10%): Venta $69.28M MXN | Uplift Neto: +$7.66M MXN (+12.8%).
    - S2 (Estratégica -20%): Venta $77.55M MXN | Uplift Neto: +$15.93M MXN (+26.7%).
    - S3 (Agresiva -30%): Venta $86.44M MXN | Uplift Neto: +$24.82M MXN (+41.5%).

Módulo 31: Desagregación Jerárquica de Pronósticos por SKU

- Notebook: 31_desagregacion_predicciones_sku (Tiempo de corrida: 0.55 min / 33 s).
- Volumen: Generación de 1,130,681 registros en gold_predicciones_sku.
- Catálogo Cubierto: 5,819 SKUs líderes abastecidos en la red.
- Metodología de Participación Móvil (Rolling Share a 28 días):

$$w_{i,s,c} = \frac{\sum_{t \in [T-28,\,T]} \text{Venta}_{i,s,c,t}}{\sum_{j \in \text{Top15}} \sum_{t \in [T-28,\,T]} \text{Venta}_{j,s,c,t}}$$

Garantiza que $\sum_{i=1}^{K} w_i = 1.0000$ exacto para cada tienda y categoría.

- Prescripción de Surtido en Unidades con Techo Conformal P90:

$$\text{Unidades Sugeridas P90} = \left\lceil \frac{Q_{P90,\text{cat}} \cdot w_i}{\max(\overline{P}_i, \$1.0)} \right\rceil$$

Traduce el riesgo de desabasto a piezas físicas exactas para el personal de almacén.

- Auditoría de Reconciliación Aditiva: 100.0% de paridad en los 14 días del horizonte (suma de SKUs = meta de categoría).

Producto de Difusión: Dashboard Interactivo AI/BI en Databricks

Se diseñó y publicó un tablero ejecutivo en Databricks AI/BI (Lakeview) sobre un Serverless SQL Warehouse, optimizado para latencia menor a 1 segundo y costo computacional eficiente:

Tabla 28. Componentes y controles del tablero ejecutivo en Databricks AI/BI

Sección del Tablero	Detalle y Componentes Clave
1. Fila de KPIs Ejecutivos Impacto Financiero de la Estrategia	• **Venta Simulada con Promoción:** $61.62M (Base) ➔ $72.72M (al 20% descuento) • **Uplift Neto de la Promoción:** $0 (Status Quo) ➔ +$11.1M MXN Netos • **Inventario Requerido P90:** $95.52M ➔ $114.09M (Capital de trabajo para blindar abasto) • **Unidades Totales de Surtido P90:** 5.91M piezas físicas
2. Panel Dinámico de Demanda Horizonte: 18 al 31 de Agosto de 2026	• **Curva Diaria:** Línea Azul (P50 Base) vs. Línea Naranja (P50 Simulado con Descuento) vs. Techo Conformal Verde (P90 de Seguridad para picos de fin de semana). • **Comparador Macro en Escalera Ascendente:** Status Quo ➔ -10% ➔ -20% ➔ -30%.
3. Guía Operativa de Surtido en Tienda Detalle Desagregado por SKU	• **Marcas Comerciales Mapeadas:** Victoria Latón 473ml, Modelo Especial, Corona Extra, etc.

Sección del Tablero	Detalle y Componentes Clave
	• **Columnas Accionables:** SKU ID, Categoría, Venta ($), Techo P90 ($) y Unidades Sugeridas.
4. Palancas de Decisión Barra Lateral Izquierda	• **% Descuento Promocional:** Parámetro libre continuo (permite simular cualquier porcentaje). • **Filtros:** Categoría | Región | Tienda | Selector de Fechas (Data-Aware) | Buscador SKU.

Fuente: 30_simulacion_escenarios_whatif.ipynb y 31_desagregacion_predicciones_sku.ipynb. Consultas sobre gold_escenarios_whatif y gold_predicciones_sku en Serverless SQL Warehouse [2, 5].

Características de Gobernanza y Despliegue:

- Parámetro Libre (descuento_pct): A diferencia de un reporte estático, el usuario puede teclear cualquier porcentaje (12%, 15%, 20%) y el motor Spark recalcula al vuelo la demanda y el Uplift sin reentrenar modelos.
- FinOps (Ahorro de Cómputo): Configuración de auto-detención (Auto-stop) tras 5 minutos de inactividad, garantizando $0 de gasto en Azure cuando el tablero no esté en consulta activa.

Figura 10. Simulación prescriptiva What-If, indicadores financieros y demanda diaria en el tablero ejecutivo. Fuente: Databricks AI/BI sobre gold_escenarios_whatif; corrida del 1 de noviembre de 2026 [2, 5].

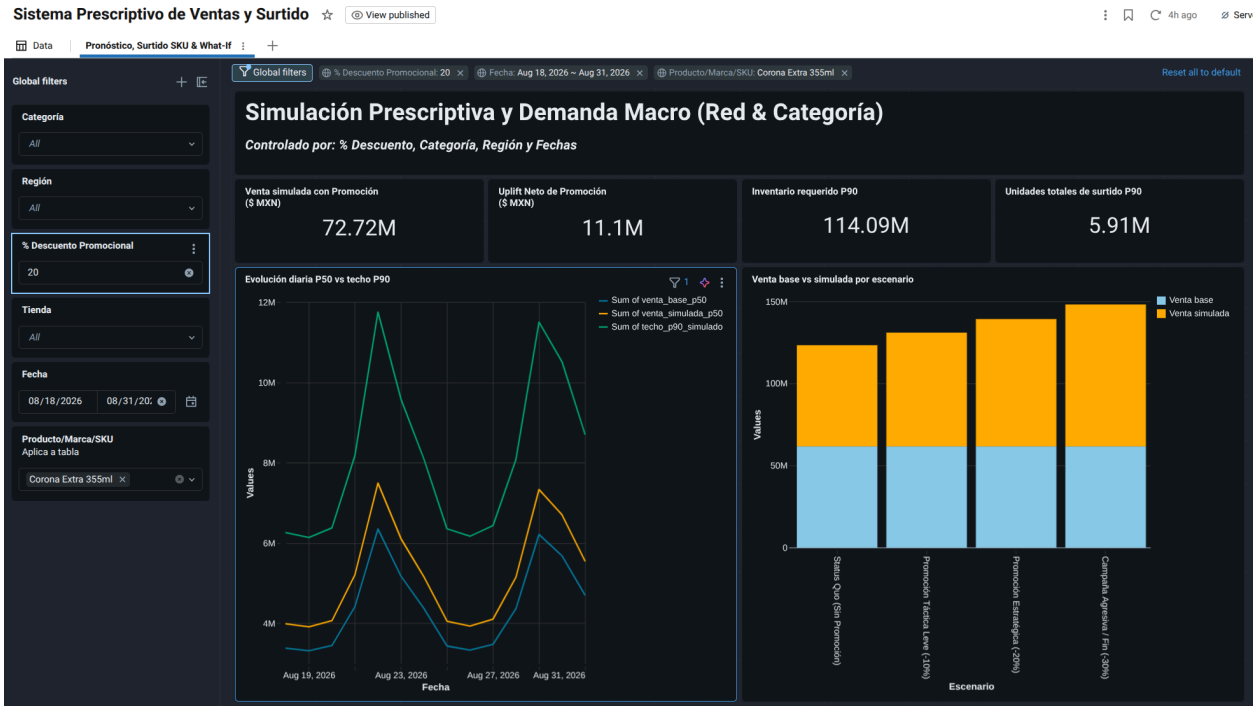
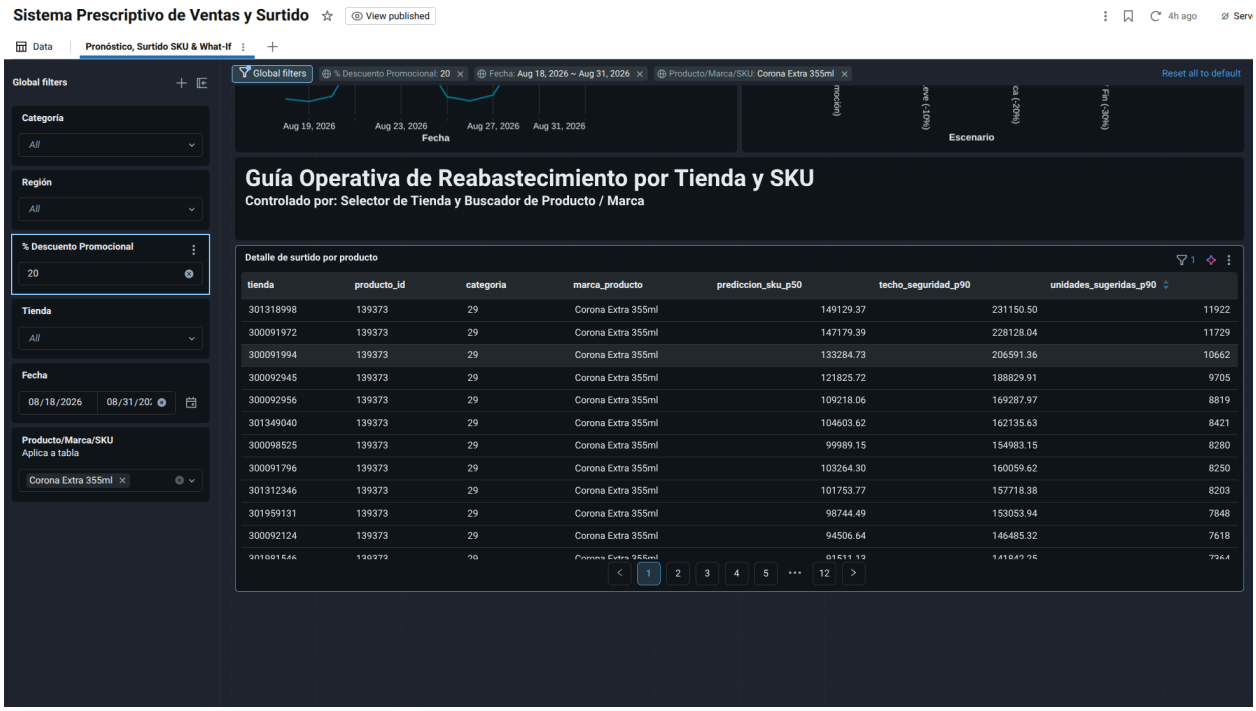


Figura 11. Guía operativa de reabastecimiento físico por tienda y SKU con techo conformal P90. Fuente: Databricks AI/BI sobre gold_predicciones_sku; corrida del 1 de noviembre de 2026 [2, 5].



El modelo matemático de predicción desarrollado en la Semana 7 ahora se encuentra plenamente operacionalizado como una herramienta prescriptiva de negocio, permitiendo que Bnext optimice tanto su estrategia comercial de promociones como el reabastecimiento físico en tienda para reducir mermas y evitar desabastos. Las actividades restantes (Semanas 9 y 10) se enfocarán en la redacción del manuscrito del artículo científico final y la formalización de la orquestación programada en Databricks Workflows.